中国移动研究项目 · 子课题一

多条件中文声纹识别与噪声鲁棒性增强

技 术 报 告(扩充版 V2)

—— 面向智能终端的开集声纹验证:注册条件化目标说话人提取 ——

张启元(中国科学院大学)

中国移动研究项目 · 子课题一

2026 年 9 月 7 日(修订版)

目录

摘要

小组成员与分工

1 任务背景与验收要求

2 声纹识别与语音增强技术基础

3 评测体系与基线

4 研究历程与路线演进

5 交付方法:模型、损失与训练

6 主线实验结果

7 消融实验

8 大、小模型与协同方案比较

9 局限性分析

10 总结与展望

未来职业规划

参考文献

附录 A 模型参数量普查; 附录 B 实验产物索引; 附录 C 部署口径(claim)分析与局限性

摘要

本报告面向 AI 眼镜、车载座舱等中文智能终端的开集声纹验证需求,解决低信噪比(0 dB、-5 dB)单说话人噪声下的说话人确认(EER)退化问题。我们从 3D-Speaker 中文数据出发建立了说话人隔离、开集验证、阈值冻结的统一评测体系,校准了三个量级的基线骨干(ECAPA-TDNN 20.8M、ERes2Net-large 29.1M、ReDimNet2-B6 12.7M),并先后排除了"冻结式后端微调"(配方迭代后增益 -8%~-16%,距 30% 达标线仍差约一倍)与"通用降噪前端"(负增益)两条自然路线;由"通用降噪抹平说话人身份特征"的负增益机理出发,提出**注册条件化目标说话人提取前端**:以注册语音的声纹嵌入通过特征级仿射调制(SpeakerFiLM)注入 FullSubNet+ 降噪网络,使其"只提取注册说话人",并配合说话人保持损失、难负原型抑制损失、判别分类损失与随机时长增强的四级迭代训练。

最终交付(验收口径):主力后端 ERes2Net-large 在 0 dB/-5 dB 的 EER 由 8.39%/11.06% 降至 **4.89%/5.56%**,相对未增强骨干降幅 **-41.7% / -49.7%**,大幅超过"降幅 ≥30%"的验收线;经典后端 ECAPA-TDNN 同步达到 -43.3% / -50.3%;轻量后端 ReDimNet2-B6 为 -23.7% / -28.2%。clean 语音无退化,非人声噪声域(music、音效)增益 -39% 以上全额迁移,混响 -20.0%、2-3 人重叠 -15.0%~-35.2%,1s/3s/5s 短语音全轴改善。

评测口径定义与部署口径(claim)分析见**附录 C**。

小组成员与分工

子课题一由 2 名成员协作完成,按"**可复现评测基座 + 鲁棒算法主线**"**双支柱**分工:数据与评测基座保证每个结论可追溯、可复现;算法主线保证每个决策都有官方口径的单次实测支撑。两人每周周报对齐进度,关键实验交叉校验。

成员	分工方向	主要工作
张启元(中国科学院大学)	算法与实验主线	子课题需求分解与达标路线设计;训练/评测环境与自动化管线搭建;鲁棒方案设计与四轮迭代(冻结微调 → 通用降噪 → 注册条件化 TSE 前端);三后端全量实验与官方终评;失败案例挖掘、ROC/DET 分析;技术报告与汇报材料。
邓姣姣	数据与评测支撑	多条件测试数据协议制定(8 种声学条件派生,注册/trial 协议统一);单说话人噪声与多人重叠数据合成(SNR/TIR 元数据记录);三重数据泄漏检查(说话人/MD5/同源切片);统一评测脚本 evaluate.py(EER、minDCF、ROC/DET、固定阈值 FAR/FRR);鲁棒性文献调研(2024-2026 五类技术路线)。

1 任务背景与验收要求

1.1 任务目标

依据《任务书》(任务.xlsx),子课题一的目标是:面向 AI 眼镜、车载座舱等智能终端,提升中文声纹识别在低信噪比和复杂声学条件下的稳定性。与"固定人员名单的闭集分类"不同,任务明确采用**开集声纹验证**:测试阶段的目标说话人不出现在训练集中,仅凭注册语音建立声纹模板;每条试验由"目标身份 + 测试语音"组成,同时包含本人试验与非本人试验。

1.2 数据与协议规定

- 以 **3D-Speaker 中文数据**[8]为主验收集(训练集 190 GB、579,003 条;测试集 240 人、18,782 条),VoxCeleb 仅用于预训练;
- 训练/验证/测试**按说话人互不重叠**划分,禁止同源切片跨集合泄漏;
- 固定注册语音数量/时长、测试时长(1s、3s、5s)、正负试验清单与比例;**判定阈值只能在验证集确定,测试集冻结**,不得重新调参;
- **主验收基线 = 骨干的未增强原版**("采用其他骨干时,还需与该骨干的未增强版本进行同条件比较"),且基线不得使用前端增强、噪声鲁棒训练、域适配或后端校准等改进;
- 测试场景:干净语音;单说话人噪声(SNR = -5 dB、0 dB);回声/混响(记录 RIR/T60);2-3 人重叠(记录 TIR);跨设备;短语音。

1.3 验收指标

层级	指标	本课题结果
挑战目标	单说话人噪声(-5 dB、0 dB 两档)EER 均 ≤ 0.5%	**未冲击(差距数量级,预期内)**
达标目标	(基线EER − 改进EER) ÷ 基线EER × 100%,两档均 **≥ 30%**	**主力 -41.7% / -49.7%;经典 -43.3% / -50.3%** ✅
其他场景	不设统一硬阈值,分项报告 EER、minDCF、ROC/DET、固定阈值 FAR/FRR,禁止合并均值替代分项	**全部分项报告(第 6 章)**
交付物	模型、权重、训练/评测代码、对比分析报告、失败案例	**全部产出(附录 B)**

> **口径说明:**达标线按任务书以"未增强骨干"为基线逐后端对照——这正是第 6 章交付大表的构成方式;即使改按子课题文本中出现的"统一 ECAPA-TDNN 基线"口径(0dB/-5dB 为 11.15%/14.36%,达标线 7.805%/10.052%),主力后端交付值 4.89%/5.56% 依然大幅过线,结论对两种口径均稳健。

2 声纹识别与语音增强技术基础

本章给出理解后续各章所需的最小背景:开集声纹验证的流程与指标(2.1、2.2)、三个基线骨干(2.3)、作为前端骨干的 FullSubNet+(2.4),以及本课题核心思想依托的目标说话人提取与 FiLM 条件化(2.5)。已熟悉这些内容的读者可直接跳至第 3 章。

2.1 开集声纹验证的流程

声纹识别分为**闭集辨认**(从固定名单中分类"是谁")与**开集验证**(判断一句测试语音"是不是声称的那个人")。本课题采用后者,完整流程为:

1. **注册(enrollment):**说话人提供若干条注册语音,经嵌入提取器 $f(\cdot)$ 映射为定长声纹嵌入,聚合为该说话人的**注册模板** e_{enr};
2. **验证(verification):**测试语音 x_t 同样映射为嵌入 e_t,与注册模板做**余弦相似度**打分:

$$\text{score}(x_t, e_{enr}) = \cos(f(x_t), e_{enr}) = f(x_t) \cdot e_{enr} / (\|f(x_t)\| \cdot \|e_{enr}\|)$$

判决:score ≥ 阈值 θ 判为目标(target,本人),否则判为非目标(nontarget,他人)。每条"测试语音 × 声称身份"组合称为一条 **trial**;开集测试集由目标 trial 与非目标 trial 按固定比例构成(本课题官方清单 1,378,206 条,目标 : 非目标 = 1 : 5.5,构建方式见 3.2)。

两条关键约束:**"开集"意味着测试说话人不出现在训练集中**——系统必须只凭注册语音建立模板,这是声纹验证与说话人分类的本质区别;**阈值只能在验证集上确定、测试集冻结**——否则相当于依据测试数据反馈调整系统参数,造成信息泄漏与评估失真(任务书明确规定,见 1.2)。

2.2 性能指标:EER、minDCF 与工作点

给定阈值 θ,记目标 trial 的分数分布为"真认分布"、非目标为"冒认分布",定义两类错误率:

$$\text{FAR}(\theta) = P(\text{score} \geq \theta \mid \text{非目标}) \ \text{(错误接受率)}, \quad \text{FRR}(\theta) = P(\text{score} < \theta \mid \text{目标}) \ \text{(错误拒绝率)}$$

θ 调低则 FAR 升、FRR 降,反之亦然——两类错误单调反向,单点错误率不能概括系统优劣。本报告采用四种互补指标:

- **EER(等错误率):**使 FAR(θ) = FRR(θ) 的共同错误率,对应 ROC 曲线与对角线的交点。EER 不依赖阈值选择、越低越好,是最常用的单值指标。例:主力后端 0 dB 3s 档 EER 从 8.39 降至 4.89(第 6 章),即错误率近乎减半。
- **ROC / DET 曲线:**全阈值范围内 FAR–FRR 的完整轨迹。DET 图将两轴作**正态概率刻度**变换,使分数近似高斯时曲线接近直线、尾部分布差异被放大,便于比较低错误率区域(本报告图 5/6)。
- **minDCF(最小检测代价函数):**NIST 评测定义的代价在全部阈值上取最小:

$$C_{det}(\theta) = C_{miss} \cdot P_{miss}(\theta) \cdot P_{tar} + C_{fa} \cdot P_{fa}(\theta) \cdot (1 - P_{tar}), \quad \text{minDCF} = \min_\theta C_{det}(\theta) / (C_{miss} \cdot P_{tar})$$

官方口径取 P_{tar}=0.01、C_{miss}=C_{fa}=1:目标先验仅 1% 意味着部署中非目标请求远多于目标,minDCF 因此对**低误报区域**的分数分布远比 EER 敏感。本课题主力 0 dB 格 minDCF 从 0.628 降至 0.515(−18%),显著小于 EER 的 −41.7%,正是这个原因(表 8)。

- **固定工作点:**FAR=5% 处的 FRR、FRR=5% 处的 FAR,直接对应部署运维的漏放行/误告警水平。例:主力 0 dB 格 FRR@FAR5% 从 12.46 降至 4.77、FAR@FRR5% 从 14.98 降至 4.77(表 8)。

2.3 三个基线骨干

本课题在同一协议下对比三个量级的说话人嵌入提取器(全部输出定长嵌入,按 2.1 的余弦打分验证):

- **ECAPA-TDNN(20.8M)**[2]:经典架构。TDNN 帧级卷积叠加 SE-Res2Block 通道注意力,经多重注意力统计池化聚合为句子级嵌入;久经验证的工业界事实标准之一,本课题作"经典后端"对照。
- **ERes2Net-large(29.1M)**[7]:Res2Net 分层残差分支 + 局部/全局特征融合,在 3D-Speaker 中文数据[8]上训练;**本课题主验收靶子**(基线锚点见表 1)。
- **ReDimNet2-B6(12.7M):**端侧轻量架构,以 12.7M 参数在部分协议反超大模型;用于考察前端增益在轻量后端的迁移(第 7.4 节)。

三骨干参数量差约 2.3 倍,恰好覆盖"端侧—经典—旗舰"三档,构成"大小模型比较"(第 8 章)的实验基础。

2.4 语音增强骨干:FullSubNet+

FullSubNet+[4] 是在 FullSubNet[3] 基础上改进的全带-子带融合单通道语音增强网络。输入 16 kHz 语音经 STFT(帧长 512、帧移 256)得 257 维复数频谱 $Y(t, f)$,网络估计一个**复数理想比例掩码**(complex Ideal Ratio Mask, cIRM)$M(t, f)$,与带噪谱相乘重建增强语音:

$$\hat{S}(t,f) = M(t,f) \odot Y(t,f)$$

结构上,**全带模型**(LSTM,隐层 512)以整谱为输入,建模全局噪声上下文;**子带模型**(LSTM,隐层 384)以每个频带及其相邻 15 个频带为输入,建模局部谱细节;二者逐层互喂、互补长短。前瞻仅 2 帧、整体近因果,满足实时性;参数 8.68M,是"因果、实时、小参数量"约束下的合理选择。

> **关键背景:**该网络的训练目标(掩码逼近干净语音)内嵌了"保留**所有**语音、去除**非语音**"的先验。当噪声本身就是**另一个说话人**时,这一先验恰好与声纹任务冲突——第 4.2 节"负增益"结论的根因即在于此,并直接导向 2.5 的条件化方案。

2.5 目标说话人提取(TSE)与 FiLM 条件化

目标说话人提取(target speaker extraction, TSE)把增强目标从"干净语音"改为"注册说话人的语音":网络除带噪输入外,还接收一份**说话人条件**(注册语音的声纹嵌入),据此决定保留谁、压制谁。VoiceFilter[5] 首次将该范式用于声纹验证:注册嵌入经仿射调制注入 LSTM 增强器,带噪验证错误率显著下降。

条件注入采用 **FiLM**[6](Feature-wise Linear Modulation,特征级线性调制)——把条件做成对中间特征的**逐通道仿射变换**:

$$\tilde{F}_c(t,f) = \gamma_c \odot F(t,f) + \beta_c, \quad (\gamma_c, \beta_c) = \mathrm{MLP}(e_{enr})$$

其中 F 为网络中间特征,γ、β 为由条件嵌入 e_{enr} 经小 MLP 生成的逐通道缩放与偏置系数,⊙ 为逐元素乘。相比只在输入端拼接条件向量,FiLM 让条件参与**特征组合本身**,表达能力强且几乎不增加参数。本课题的 SpeakerFiLM 即其工程实现(仅 0.52M,详见 5.1.2),并对调制层采用**零初始化**(γ=1、β=0),保证训练起点严格等价于无条件版本——条件能力在通用基座上渐进获得,而非通过整体重训获得。

本章所引文献见文末参考文献。

3 评测体系与基线

3.1 官方协议校准(管线可信性)

第一步用三个模型的官方预训练权重复现官方 cross-device / cross-distance / cross-dialect 三协议共 535,163 条 trial,与论文值对账:

模型	我们实测 cross-device EER(%)	论文值(%)	偏差
ECAPA-TDNN(20.8M)	9.31	8.87	+0.44 pp
ERes2Net-large(29.1M)	6.87	6.34	+0.53 pp

三个协议全部复现,偏差 < 0.6 pp;cross-dialect 最难(12-15%);轻量后端 ReDimNet2-B6 在 cross-distance 反超 ERes2Net。**评测管线由此证明可信。**

3.2 统一多条件基准

在 240 个官方测试说话人上构建四类角色划分——A 注册+正样本(180 人)、B/C 中文重叠干扰(15+15 人)、D 负样本/冒认(30 人)——另自 MUSAN speech(librivox)取 173 个英文说话人作 E/F 英文重叠干扰角色(中文侧 A+B+C+D 恰为 240 人、18,782 条;英文干扰为外部池,每人 1 条);一套注册语音(A 角色全部 8,687 条 clean)+ 一套试验清单 + 八套测试语音(clean、noise_0dB、noise_-5dB、混响、二/三人重叠 × 中文/英文);噪声取 MUSAN free-sound 段,训练池 615 条与测试池 168+ 条**严格隔离**;0 dB 与 -5 dB 同噪声同位置仅 SNR 不同;混响用模拟中等房间(T60 中位 0.60 s);重叠场景记录 TIR。全流程 seed=2026 固定可复现;打分文件采用官方格式 trials_cross_device 共 **1,378,206 条**(目标 211,400 : 非目标 1,166,806 = 1 : 5.5)。EER 由官方打分脚本插值计算,自建复算脚本与之逐位对齐(自检:官方全文复算 EER 4.8921 vs 官方 4.892)。

清单构成实测(9.6 统计):对全部 1,378,206 条 trial 的 utterance 编码逐条统计——设备维度 100% 跨越(协议保证);同时**距离维度 93.9%、方言维度 87.1%、录音会话 97.1%** 的 trial 也在跨越,仅 4.8% 是"只跨设备、同距离同方言"的纯净对。也就是说,该主基准在事实上是**多条件复合**评测(跨设备为主、混入大量跨距离/跨方言对)——这也是其 EER 显著高于 clean 的原因之一,报告所有结论均建立在这一(更难的)复合口径上。

3.3 未增强基线锚点(主线一切对比的起点)

表 1 | 统一多条件基准的未增强基线 EER(%)

后端(参数量)	clean	0dB 1s	0dB 3s	0dB 5s	-5dB 1s	-5dB 3s	-5dB 5s
ERes2Net-large(29.1M)**主验收靶子**	5.29	18.56	**8.39**	7.86	21.44	**11.06**	10.08
ECAPA-TDNN(20.8M)	6.92	24.51	11.15	10.36	27.47	14.36	13.37
ReDimNet2-B6(12.7M)	6.13	21.73	9.94	9.50	25.55	13.03	12.35

注:验收档为 0dB/-5dB 3s(30% 线对应达标线 5.874/7.739);clean 列为 cross_device 3s 口径,ECAPA/B6 两格 9.4 补齐,补齐时 ERes2Net 复测 5.2928 与 8.28 锚 5.293 逐位一致,互为协议验证(见 6.1)。

4 研究历程与路线演进

4.1 第一阶段(7.20-7.31):全量基线与基建

4 卡 Tesla P100 服务器搭环境,190 GB 3D-Speaker 就绪,三模型官方协议校准(3.1 节)。横向结论:方言/cross-dialect 最难;ERes2Net 全面领先 ECAPA 约 20-26%;B6 以 12.7M 参数在部分协议反超——确立"多量级对比"的价值。

4.2 第二阶段(8.3-8.24):两条自然路线先后中止

表 2 | 两条起点路线的排除记录(全链明细见表 2b)

路线	做法	结果	判决
冻结式后端微调	冻结底层卷积与 BN 统计,在线多条件微调(8.20/8.21 重写配方,完整配置见下文)	0dB 8.39→7.69、-5dB 11.06→9.88;级联 7.50/9.51,分数融合最好 7.25/9.27	**增益不足,未继续深入**
通用降噪前端	FullSubNet+ 以信号重建为目标,降噪后语音送验证器	0dB 降噪后 10.11,比带噪 8.39 **还差 1.72pp**	**负增益,判定为无效路线**

冻结式微调的具体做法(8.20/8.21 重写配方):训练数据取 9,900 个训练说话人(与代理验证 100 人、官方测试 240 人三方互斥,准备脚本运行时断言)中等距抽取的 30,000 条;同一句语音在每个 epoch 动态生成 clean / 0dB / -5dB 三个版本(随机 3s 裁剪、随机训练噪声与随机偏移),每个 batch 严格 1:1:1。模型侧冻结 conv1/bn1/layer1/layer2(含 BN 统计量,防带噪统计漂移污染冻结层),layer3/layer4、特征融合与池化层解冻训练;9,900 类分类头不再随机初始化,改由预训练 ERes2Net 的逐说话人 clean 原型(嵌入质心、L2 归一)初始化并逐位回读校验;lr 2e-5、AAM-Softmax(margin 0.2、scale 32)、8 epoch。(该配方为归因重写版:首版经验式配方曾致八条件中六套退化,重写后全线转正;首版明细见《实验结果汇总》§2.1 留档。)

表 2b | 后端微调线的全链尝试(EER %)

配置(官方协议,trials_cross_device/3s)	clean	0dB	-5dB
未增强基线(pretrained ERes2Net)	5.29	8.39	11.06
robust 后端(8.21,原型初始化 + 1:1:1 微调)	**5.10**	7.69 (-8.3%)	9.88 (-10.7%)
微调通用前端(8.18,加身份保持正则)	—	7.79 (-7.1%)	9.92 (-10.3%)
前端 + robust 后端级联	—	7.50 (-10.6%)	9.51 (-14.0%)
+ 跨系统分数融合(grid 最优)	—	7.25 (-13.6%)	9.27 (-16.2%)
理论加性上限(前后端增益独立叠加)	—	≈7.09 (-15.5%)	≈8.74 (-21.0%)
30% 达标线	—	**5.874**	**7.739**

注:全部为官方协议实测(出处:AI/8.21 组合评测与 8.24 当期留档);配方修正后全线转正、clean 无退化,但距 30% 线始终差约一倍(级联 7.50/9.51 距线 1.63/1.77pp);五模型权重汤 soup5(7.61/9.72)见表 14。

中止该路线的三点依据:①幅度——全链最好成绩距 30% 线仍差 1.4~1.8pp,约为所需降幅的一半;②重叠——后端只被原始带噪域校准过,级联实测(7.50/9.51)明显逊于前后端增益独立叠加的上限(≈7.09/8.74),两路增益互相侵蚀;③机会成本——同期注册条件化前端单级即达 -33.5%/-40.9%(表 13)。微调线的最终产物 soup5(7.61/9.72)转用作训练期冻结验证器(表 3 轮 0),仍在交付链中发挥复用价值。

机理定位:分离度分析显示降噪抹平了跨句稳定的说话人身份特征(目标对分数均值 0.422→0.391)。这一"负增益"发现是全课题最重要的转折点——它证明语音增强做声纹前端,不能以 SNR/信号保真为目标。

4.3 关键转折:单说话人噪声本质是"干扰语音"问题

> 任务场景中的噪声是**另一个说话人在说话**。通用降噪器的目标是"保留所有语音、去掉非语音",因此会把干扰语音完整保留——问题并非降噪能力不足,而是**任务定义不当**。正确任务是:只提取注册说话人的语音(target speaker extraction, TSE)。而"该提取谁"这一信息,恰好可以由注册语音提供——注册语音本来就是验证系统自带的输入。

4.4 第三阶段(8.24-8.28):注册条件化 TSE 的四轮迭代

VoiceFilter 式设计:注册语音过冻结声纹后端得 512 维嵌入,经 SpeakerFiLM 模块对 FullSubNet+ 做仿射调制(详见 5.1)。迭代按"每级只加一个变量"推进,全部在代理验证集选点、官方测试单次实测:

表 3 | 注册条件化迭代链(轮 0-6 冻结验证器口径,轮 7 交付口径)

轮	在上一版基础上	0dB	-5dB
0	未增强 raw(冻结验证器口径)	7.614	9.715
1	接入条件化前端:仅 L_{se}+L_{ce} 基座适配训练,未加任何说话人侧损失	7.38	9.32
2	+ 说话人保持损失(系数 0.3)	7.293	9.202
3	+ 难负原型抑制损失(系数 0.5)	6.519	8.173
4-6	同配方延长续训 ×3(第 4 轮回归 → 止损)	5.766 → 5.467 → **5.235**	6.972 → 6.462 → **6.098**
7	+ 随机时长增强续训 = **交付前端**(换回预训练后端)	**4.89**	**5.56**

轮 1 的准确含义(接入官方打分链路,而非分数融合):把 8.26 版条件化前端接入官方打分链路——FullSubNet+ 装载 8.18 通用基座权重,SpeakerFiLM 末层零初始化、恒等起步;推理增强时以**说话人粒度**的注册嵌入为条件(该说话人官方注册 clean 过冻结 soup5,均值+L2;同一条件覆盖该说话人的注册侧与打分侧全部语音),增强语音直接送同一冻结验证器打分。该级前端做过 3 轮**基座适配训练**(损失仅 L_{se} 重建 + L_{ce} 判别分类,四损失中说话人侧的 L_{spk}/L_{ns} 均尚未引入)——"接入后 7.38/9.32"相对轮 0 锚点 -3.1%/-4.1%,验证注册条件化方向本身有价值。此步不涉及任何分数级融合(降噪分支+原始分支的分数加权融合是 8.22-8.25 的独立支线,经验证无效后弃用,见《实验结果汇总》§2.3)。

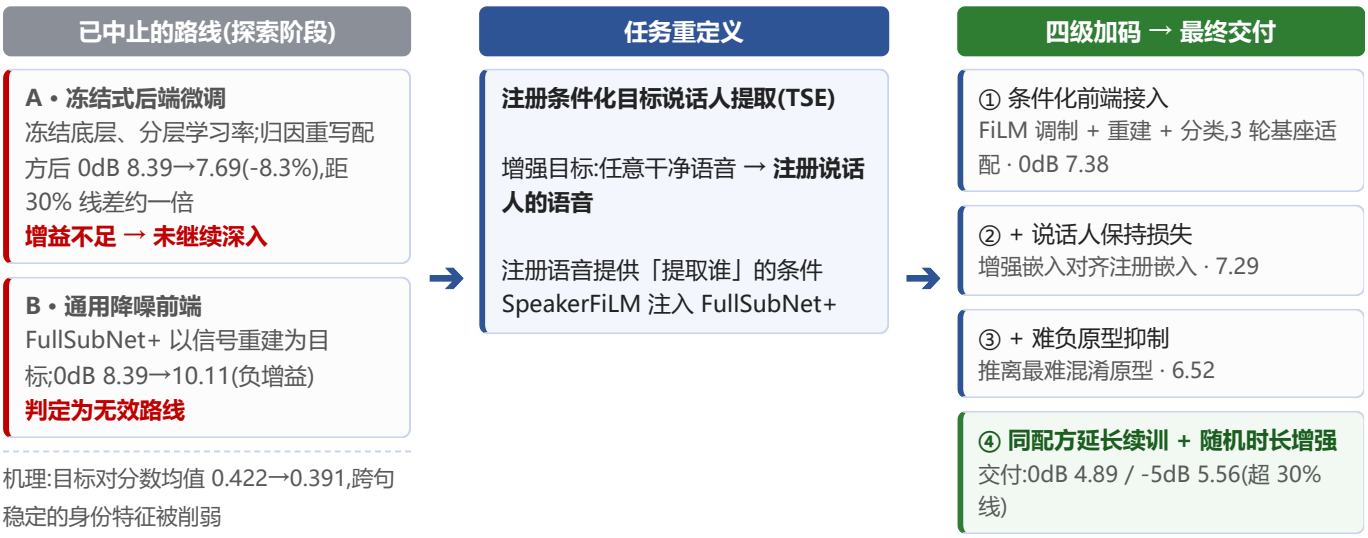


图 1 | 研究路线图(①-③ 冻结验证器口径、④ 交付口径;与汇报 PPT 第 8 页对应)

5 交付方法:模型、损失与训练

5.1 模型结构

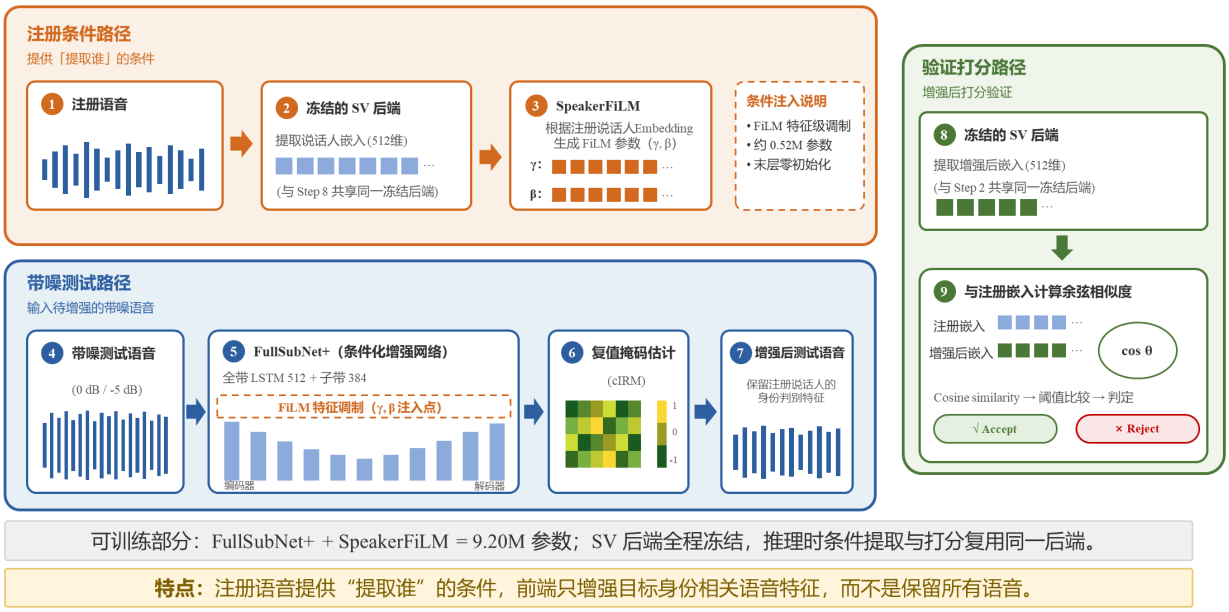


图 2 | 交付前端结构(与汇报 PPT 第 13 页同图)

5.1.1 骨干:FullSubNet+

全带-子带融合降噪网络(结构详见 2.4)。输入 16 kHz 语音,STFT(帧长 512、帧移 256)得 257 维频谱;全带模型(LSTM,隐层 512)建模全局噪声上下文,子带模型(隐层 384,每子带看相邻 15 个频带)建模频带细节;输出复数理想比例掩码 cIRM,与带噪谱相乘重建增强语音。选它的原因:因果、实时、参数量小,且上一阶段的失败经验(4.2)正是在该骨干上取得——失败机理数据可直接复用。

5.1.2 条件化模块:SpeakerFiLM(FiLM 特征级仿射调制)

注册语音过**冻结**声纹后端得 512 维说话人嵌入 e_{enr}(评测实现:该说话人注册 clean 各条 3 s 定长 → 冻结后端 → 均值 → L2 归一)——它就是"提取谁"的条件。FiLM 的思想(2.5)是把条件做成对网络中间特征的**逐频带仿射变换**:

$$(\gamma, \beta) = \mathrm{MLP}(e_{enr}), \quad \tilde{F}(t, f) = \gamma \odot F(t, f) + \beta$$

真实实现(tse_model.py):MLP 为 Linear(512→256) → ReLU → Linear(256→1,542),1,542 个输出拆为三路(复数谱**幅度 / 实部 / 虚部**)各自的 γ、β——每路 257 维**逐频带系数向量**,γ、β 的 shape 均为 (B, 3, 257),不是两个标量。注入位置在 FullSubNet+ 全带分支三路输入上:每路先过批归一化与 TSSE 通道注意力(channel_attention / channel_attention_real / channel_attention_imag),紧随其后做 FiLM 仿射,再进各自的全带 LSTM(fb_model / fb_model_real / fb_model_imag,隐层 512)。γ、β 沿时间轴广播:γ_k、β_k 由 (B, 257) 升维为 (B, 257, 1),作用于 (B, 257, T) 的特征——同一频带的所有帧共享该频带的一组缩放/偏置系数,257 个频带各有独立系数。SpeakerFiLM 的三个设计决策:

- **注入位置——特征级、掩码估计之前:**条件直接参与"该保留哪个说话人"的掩码估计过程,而不是在输出端对增强语音做事后修饰——后者无法影响子带级的谱细节决策。γ、β 逐频带作用于特征,等价于让网络对每个频带学习"在当前目标说话人下该放大还是抑制";FiLM 后的幅度特征还随邻域展开进入子带输入,条件信息同时抵达全带与子带两级。
- **末层零初始化(γ=1, β=0)——工程保险:**生成 (γ, β) 的 MLP 最后一层**权重与偏置全部**零初始化,三路调制初始均为恒等变换,训练起点**严格等价于**无条件版通用前端——8.18 已训练好的通用基座能力不因新增模块被破坏,条件信息随训练逐步注入(实际生效集中于幅度路,见下文说明)。这是条件化模块能以增量方式叠加在既有基座上的关键。
- **代价——仅 0.52M 参数,开集友好:**两层 Linear(512→256 / 256→1,542)共 0.52M,前端总参数 9.20M(附录 A);条件嵌入来自**与打分同一个冻结后端**,无需像 VoiceFilter 那样额外部署一个 d-vector 网络,全栈 ≈ 31.7M 参数(约 127 MB fp32),额外推理代价仅每句一次 FiLM 前向。MLP 权重是全部说话人**共享**的唯一条件参数——测试遇到训练未见说话人时,直接用其注册嵌入现场前向生成专属 γ/β,不保存任何按说话人的固定调制参数,新说话人零成本接入。

交付实现的一个如实说明(代码级):子带输入的三个"全带输出展开"槽位,在交付代码(tse_model.py)中均取**幅度路**全带 LSTM 的输出 fb_output——与 FullSubNet+ 原版 forward 三路各取各自输出的写法不同,系 8.26 条件化改造时引入并沿用至交付版。其后果是:实部/虚部两路的 FiLM 注入虽然存在于结构中,其后级输出并不进入子带输入,训练中这两路 γ/β 梯度恒为零、始终保持零初始化的恒等;条件作用实际经由两条途径生效——①幅度路 γ/β 调制幅度特征、进入幅度全带 LSTM;②FiLM 后的幅度特征另按子带邻域(相邻 15 带,共 31 列)展开,直接构成子带输入的一部分。即条件既改写全带上下文,也直抵子带掩码估计;全部交付数字均由该实现实测得出。

5.2 损失函数:四项各司其职

> **设计原则:**整个训练只更新前端 9.20M 参数——FullSubNet+ 骨干(8.68M)与 SpeakerFiLM(0.52M)在同一 Adam 优化器中**联合更新**;声纹后端(soup5 验证器)与 AAM 分类头 requires_grad=False 且不进优化器,**参数全程不变**(梯度仅穿越其计算图回传前端)——增强器被"当成"冻结验证器的可训前级,训练所用嵌入与推理打分所用嵌入出自同一网络,训练目标与评测目标严格一致。总损失为四项加权和(交付版取 λ_{spk}=0.3、λ_{ns}=0.5、λ_{ce}=1.0):

$$L = L_{se} + \lambda_{spk} \cdot L_{spk} + \lambda_{ns} \cdot L_{ns} + \lambda_{ce} \cdot L_{ce}$$

(1) 信号重建损失 L_{se}——防退化锚

$$L_{se} = \| \hat{M} - M_{cIRM} \|_2^2$$

$\hat{M}$ 为前端估计的复数掩码,M_{cIRM} 为理想掩码("干净语音谱 ÷ 带噪谱",由训练时在线混合的干净语音与噪声即时计算)。该项约束前端首先是一个合格的降噪器——没有它,后三项说话人侧损失可能诱导网络输出虽可通过验证器、却偏离目标说话人干净语音的退化结果。它是全部条件化能力的地基,自通用基座阶段一直保留。

(2) 说话人保持损失 L_{spk}——只管目标侧

$$L_{spk} = 1 - \cos(e_{enh}, e_{enr}), \quad e_{enh} = f(\text{增强语音}),\ e_{enr} = f(\text{注册语音})$$

两个嵌入均由同一冻结后端 f 提取(训练实现:参考锚取**同句干净语音**的嵌入、no_grad 计算,与推理时的注册嵌入同后端同空间)。动机来自 4.2 的负增益机理:通用降噪会把增强语音的嵌入**拉离**注册嵌入(降噪抹平跨句稳定的身份特征);该项显式把增强嵌入拉回注册说话人方向,直接对齐验证打分所用的量——优化它就是在优化打分本身。第 2 轮引入,官方增益约 −4~−5%;系数 0.3 由剂量消融选定(7.2:倒 U 形剂量响应,0.1 与 0.5 均更差)。注意其作用范围:只出现在"注册者本人的混合语音"上(目标侧),不涉及冒认侧。

(3) 难负原型抑制损失 L_{ns}——在线难负挖掘

$$L_{ns} = (1/K) \cdot \Sigma_{k \in TopK} \max(0, \cos(e_{enh}, p_k) - \tau), \quad K = 8,\ \tau = 0.30$$

原型库 $\{p_k\}$ 取自 9,900 说话人 clean 原型表(prototypes.npz)——由**原始预训练 ERes2Net** 逐说话人提嵌入质心(每人 ≤8 句居中裁 3 s,逐条 L2 → 均值 → 再 L2),说话人与官方测试零交集;该表同时作为 L_{ce} 分类头的初始化权重行,相当于"已有说话人空间"的一张静态地图。对每个 batch 的增强嵌入 e_{enh},计算分三步:

1. **排除真说话人:**先把 e_{enh} 所属说话人自己的原型从候选中剔除(实现:真说话人位置的相似度置 −2)——否则"离真原型近"这一正确行为会被误罚;
2. **在线挑难负:**计算 e_{enh} 与全部剩余原型的余弦相似度(实现:L2 归一嵌入对 9,900×512 冻结原型表的线性内积),取**最高的 K=8 个**——它们是与注册者最易混淆的"最难负类"原型,惩罚它们对判别最有信息量;
3. **合页惩罚:**对每个难负原型,余弦压到 τ=0.30 以下不再罚,超过则线性罚——只拉间隔、不做过度打压,避免干扰正常特征学习。

净效果:持续把增强嵌入推离其他说话人的嵌入区域,在冻结验证器的嵌入空间直接拉大目标/非目标判别间隔。关键工程事实:**难例在每个 batch 在线挑选、损失即时计算——全程不改数据分布,没有任何重采样或样本加权**;"难例利用"只存在于损失函数内部与验证选点(5.4),数据侧完全干净。第 3 轮引入,官方增益约 −10~−11%,是四级加码中单级贡献最大的损失(消融见表 12:λ_{ns} 增益单调未饱和,且"通用最难原型池"优于"同域定向原型池"——难比"域匹配"更重要)。

(4) 判别分类损失 L_{ce}——AAM-Softmax(角间隔分类)

$$L_{ce} = -\log e^{s \cdot \cos(\theta_y + m)} / \left(e^{s \cdot \cos(\theta_y + m)} + \Sigma_{j \neq y} e^{s \cdot \cos \theta_j} \right)$$

其中 $\cos \theta_j = w_j \cdot e_{enh} / (||w_j|| \, ||e_{enh}||)$ 为增强嵌入与第 j 个原型(分类头权重行 w_j)的余弦,y 为真说话人下标,超参 s=32、m=0.2。AAM-Softmax(加性角间隔[9])的要点:对真类别的判定角 θ_y 额外加上间隔 m 再进入 softmax——训练时真类别须以超过间隔 m 的优势胜出,迫使嵌入在空间中压出更宽的类间间隔;尺度 s 控制 softmax 的锐度。与标准用法的关键差别:此处分类头**由预训练 ERes2Net 的 9,900 说话人 clean 原型表初始化并保持冻结**,相当于一个永不更新的"免费教师"——把预训练模型已有的判别结构作为固定靶子,梯度只回传前端,让前端朝"验证器心目中的好嵌入"优化。该项自第 1 轮基座接入期即与 L_{se} 同在;第 3 轮叠加 L_{ns} 后,二者一个推离难负、一个拉近真类,共同构成完整的判别约束。

表 4 | 损失族汇总

项	约束目标	系数	引入轮次与官方增益
L_{se}	掩码逼近理想 cIRM(保证仍是合格降噪器)	1.0	通用基座自带
L_{spk}	增强嵌入对齐注册嵌入(目标侧拉回)	0.3	第 2 轮,−4~−5%
L_{ns}	推离最难混淆原型(拉大判别间隔)	0.5	第 3 轮,−10~−11%
L_{ce}	AAM 角间隔分类(免费教师定靶)	1.0	第 1 轮(基座接入期)即引入

注:另有段级随机 {1,2,3}s 时长增强(修 1s 短语音),属数据侧增强而非损失,配置见表 5。

5.3 实验条件与训练参数

表 5 | 实验条件与关键参数

项	配置
硬件	4 × Tesla P100-PCIE-12GB(nvidia-smi 实测);训练期与全量评测期共享使用,每卡独占单任务
训练数据	3D-Speaker 中文(说话人隔离);每轮抽样 30,000 条;噪声:MUSAN free-sound 训练池 615 条,SNR ∈ {0, -5} dB;段长 3.0s(交付版随机 {1,2,3}s)
声学前端	16 kHz,STFT 512/256,257 维频带
模型	FullSubNet+(全带 LSTM 512 / 子带 384,邻域 15,前瞻 2 帧)+ SpeakerFiLM(0.52M);自 8.18 通用基座(10 轮)叠加起步
优化	lr 1e-5,batch 2,每 worker 6;每级续训 3 轮;seed=2026;延长续训阶段以代理验证集(含困难试验子集)选点,逐轮延长同配方训练
验证器/原型	冻结五成员权重汤 soup5(29.1M);AAM 头与 L_{ns} 原型表 = 预训练 ERes2Net 的 9,900 说话人 clean 质心(L2 归一)
训练纪律	代理验证集(100 未见说话人,1:5.5 对齐官方)选点;官方测试每个决策只跑一次;启动守卫(ckpt-config 一致性、manifest 校验);收敛守望(增益 <0.08pp 自动停)
评测	官方 trials_cross_device(1,378,206 条);EER/minDCF 官方脚本;三卡并行一天完成交付大表

5.4 训练流程与推理部署

5.4.1 每级训练的完整流程

第 4.4 节的每一级迭代都严格走同一条流程,保证级间可比:

1. **确定性抽样:**从 190 GB 训练集(说话人与测试完全隔离)按 np.linspace 等距抽 30,000 条,各级迭代使用**同一子集**——差异只来自训练配方,不来自数据;
2. **在线随机混合:**TSEMixDataset 在每次取数时动态合成训练样本——随机抽 MUSAN free-sound 噪声(训练池 615 条,与测试池严格隔离)、随机 SNR ∈ {0, −5} dB。同一句干净语音在每个 epoch 得到不同的噪声与信噪比组合,等效无限增广;混合即时计算、不落盘,不存在预生成泄漏;

3. **前向与损失:**注册语音(该说话人 clean)过冻结后端得 e_{enr} → SpeakerFiLM 调制 FullSubNet+ → 得增强语音 → 按 5.2 计算四项损失;Adam(lr 1e-5、batch 2),每级 3 轮;
4. **代理验证选点:**100 个训练/测试均未见过的说话人构成代理验证集(正负比 1:5.5 对齐官方),含按嵌入相似度挖掘的**困难试验子集**;每个 checkpoint 在此集上选点,**预声明判据**通过才允许触发官方测试——防止用测试集反馈调参;
5. **官方测试单次实测:**在冻结的官方 trials_cross_device 清单上跑一次、只跑一次,结果记档,作为该级的"判决"。

5.4.2 延长续训(同配方分段延长)

第 3 轮引入 L_{ns} + L_{ce} 后官方增益显著(0dB 8.39→6.52),且剂量消融(表 12)显示 λ_{ns} 增益单调未饱和,遂采用**同配方延长续训**继续下压:以上一轮 checkpoint 为起点,数据、损失、超参完全一致再训 3 轮(优化器状态重置),循环 3 段(表 3 轮 4-6),逐段官方实测持续改善(0dB:6.519 → 5.766 → 5.467 → 5.235);尝试再延长时官方实测回归(+17.7%),按预声明止损线停机。再次强调:"难例利用"只存在于两处——损失内的在线难负挖掘(5.2)与代理验证的困难试验子集选点(本节)——数据侧无任何重采样或加权。

5.4.3 推理与部署形态

注册阶段(一次性):注册语音过冻结后端得 e_{enr},缓存为该用户模板。**验证阶段(每次):**带噪测试语音 + e_{enr} → SpeakerFiLM 现场由该嵌入生成 γ/β(逐频带向量,5.1.2)→ FiLM 条件化增强(9.20M)→ 同一冻结后端提嵌入 → 与缓存模板余弦打分 → 冻结阈值判决。条件提取与打分**复用同一后端**——相比 VoiceFilter 需要独立 d-vector 网络的方案,省一份模型部署;全栈 31.7M / 约 127 MB(fp32,附录 A),前端近因果、支持流式处理,适配 AI 眼镜、车载座舱等终端场景。

运行速度实测(加前端的代价):以同批官方测试集(16,401 句 × 3s)在 Tesla P100 上的批量推理实测——**原始路径**(仅 ERes2Net-large 嵌入提取,batch 16)523 s,**31.9 ms/句**(RTF ≈ 0.011);**前端增强**(SpeakerFiLM + FullSubNet+,batch 8)两次独立实测 655 s(8.28 噪声档)与 668 s(9.3 clean 档),**40.0-40.7 ms/句**(RTF ≈ 0.014),跨日跨负载一致性 ±2%;**加前端后的整链**(增强 + 嵌入 + 余弦)约 **72 ms/句,RTF ≈ 0.024**,单卡吞吐约 14 句/s。即:单句验证耗时约为原来的 2.3 倍,前端自身开销约为后端嵌入的 1.3 倍——前端参数量虽只有后端的 1/3(9.2M vs 29.1M),但"全带 + 257 个子带 LSTM"逐帧展开的结构计算密度更高。RTF 远小于 1,实时性无虞。说明:以上为服务器 GPU 离线批量口径(含 wav 读写与 STFT/ISTFT,批量 8/16),流式单句首包延迟与终端芯片(NPU/DSP)上的实测留作后续评估。

6 主线实验结果

6.1 交付大表(验收口径)

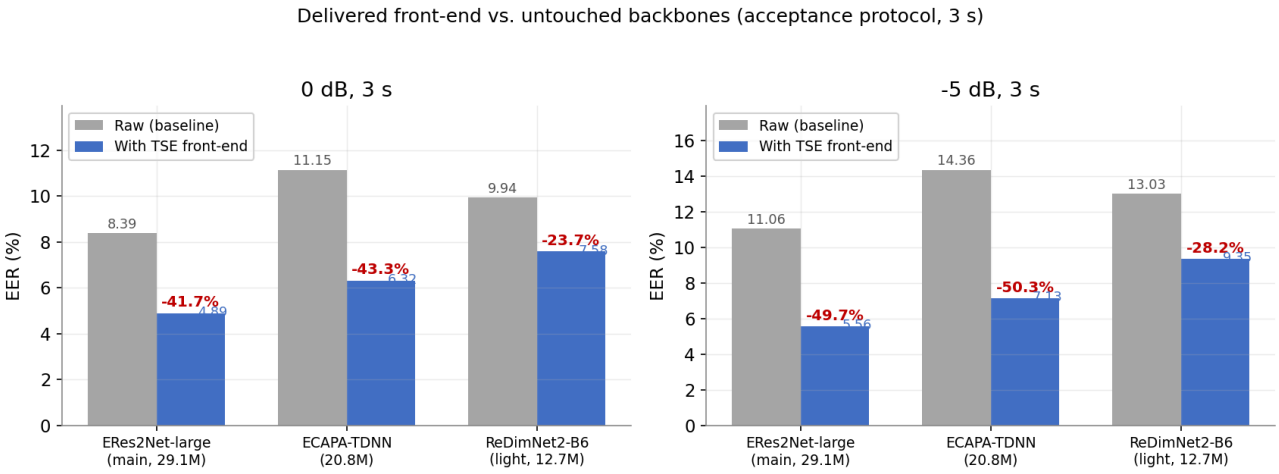


图 3 | 三后端交付对比(3s)

表 6 | 交付大表(EER %,验收档 3s)

后端	0 dB(raw → 前端,降幅)			-5 dB(raw → 前端,降幅)		
	1s	3s	5s	1s	3s	5s
ERes2Net-large	18.56→13.57 **-26.9%**	**8.39→4.89** **-41.7%**	7.86→4.43 **-43.6%**	21.44→14.74 **-31.2%**	**11.06→5.56** **-49.7%**	10.08→4.90 **-51.4%**
ECAPA-TDNN	24.51→18.35 -25.1%	**11.15→6.32** **-43.3%**	10.36→5.74 **-44.6%**	27.47→19.59 -28.7%	**14.36→7.13** **-50.3%**	13.37→6.36 **-52.5%**
ReDimNet2-B6	21.73→18.36 -15.5%	**9.94→7.58** **-23.7%**	9.50→7.20 -24.2%	25.55→20.76 -18.8%	**13.03→9.35** **-28.2%**	12.35→8.82 -28.6%

- **验收档(3s):**主力 -41.7%/-49.7%、经典 -43.3%/-50.3%,均大幅超过 30% 线;轻量 -23.7%/-28.2%,差约 2pp 未过(其嵌入判别面与前端增益的兼容性问题,见 7.4/9)。
- **时长轴:**1s 相对偏弱(0dB -26.9%,差 3pp),随机时长增强后 5s 最强(-51.4%~-52.5%)。
- **clean:**最优增强格(0dB 5s 4.43)已低于未增强 clean 基线 5.29;9.3 补做直测——clean 测试集(16,401 条)整体过 r5 前端后 EER = **4.17**(minDCF 0.445),较未增强 5.29 相对改善 21%,"clean 无退化"由推断升级为**实测正增益**(前端顺带完成跨设备通道归一与注册信息注入;产物 AI/9.3/fe_clean/)。**clean 基准三后端 × 三时长全格补测(9.4,纯 CPU 复算)**:ERes2Net 13.37 / 5.29 / 5.06、ECAPA 18.55 / 6.92 / 6.57、ReDimNet2-B6 15.46 / 6.13 / 6.00(依次为 1s/3s/5s,cross_device)——三后端时长衰减形态同构、后端排序与带噪轴一致;其中 ERes2Net 3s 独立复算 5.2928 与原锚 5.293 逐位一致。

6.2 其他场景(分项报告)

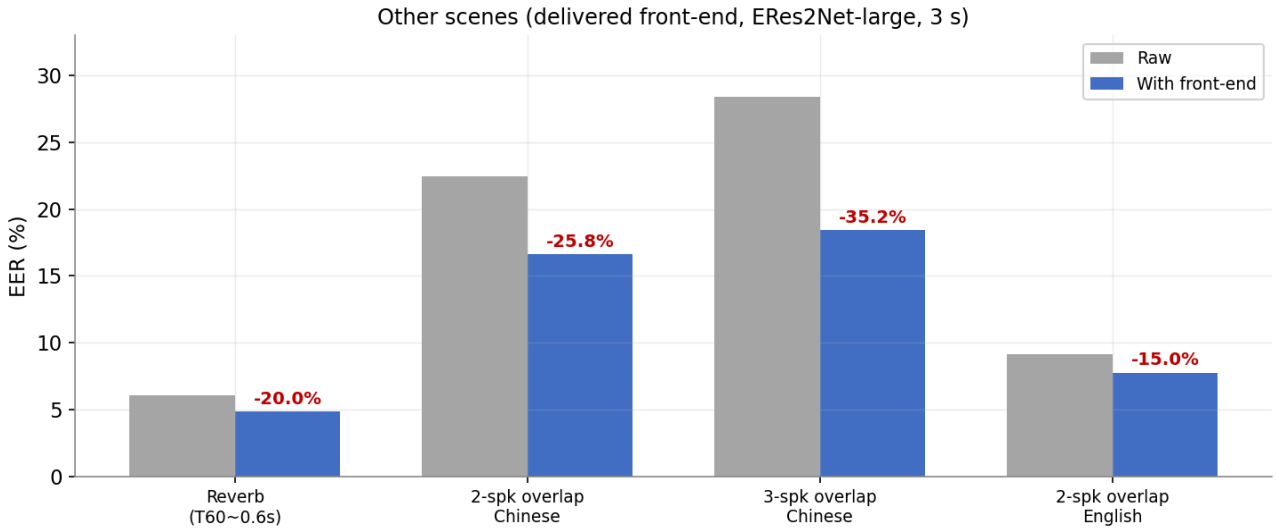


图 4 | 其他场景分项对比(主力后端,3s)

表 7 | 其他场景分项(主力后端,3s)

场景	raw	前端	降幅	说明
回声/混响(T60 中位 0.60s)	6.09	4.87	**-20.0%**	模拟 RIR 卷积
二人重叠·中文(TIR=0dB)	22.42	16.63	-25.8%	干扰为竞争说话人
三人重叠·中文	28.43	18.42	**-35.2%**	
二人重叠·英文	9.13	7.76	-15.0%	英文干扰下增益部分衰减

注:固定阈值 FAR=5% 的 FRR 口径 2/3 场景达标(工作点全表见表 8)。

6.3 ROC / DET 与固定工作点

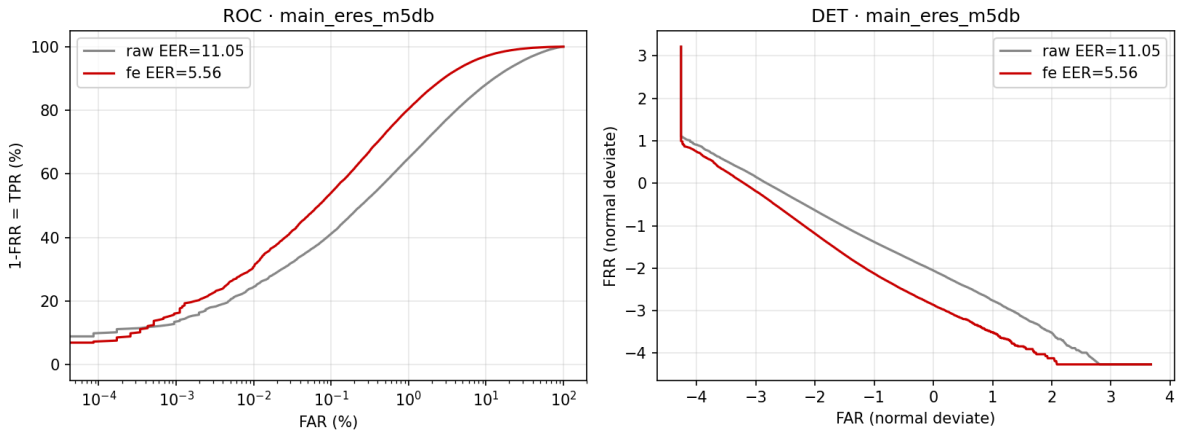


图 5 | 主力后端 -5dB 的 ROC 与 DET(原始 vs 前端)

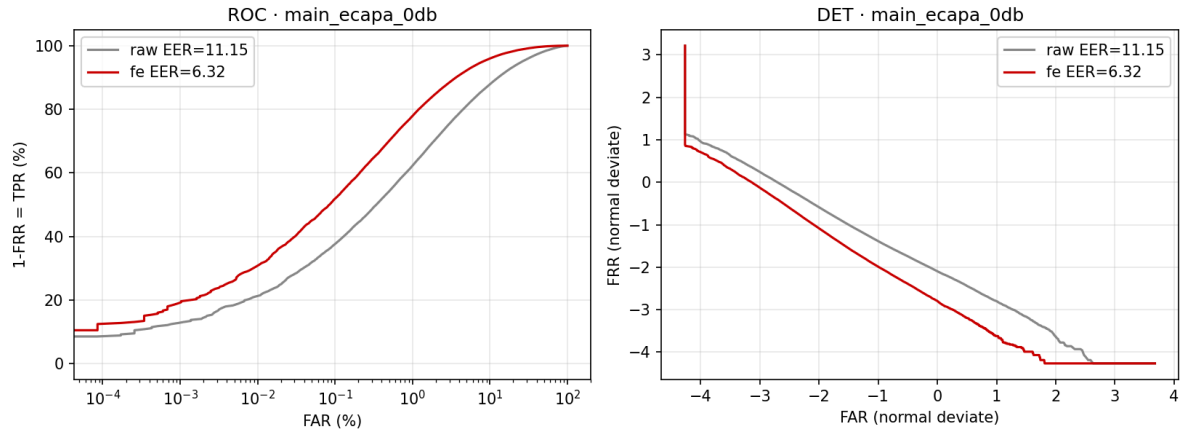


图 6 | 经典后端 0dB 的 ROC 与 DET(原始 vs 前端)

注:两图均由官方打分文件后处理生成(gen_roc_det.py,2001 阈值点,DET 轴为正态概率刻度),自算 EER 与官方对账 <0.5pp;threshold–FAR–FRR 曲线数据见附录 B。

表 8 | 8 个评测格的 minDCF 与固定阈值工作点(raw / 前端成对)

评测格(3s)	EER(%)		minDCF(p_{tar}=0.01)		FRR @ FAR=5%(%)		FAR @ FRR=5%(%)	
	raw	前端	raw	前端	raw	前端	raw	前端
主力后端 0 dB	8.39	**4.89**	0.628	**0.515**	12.46	**4.77**	14.98	**4.77**
主力后端 -5 dB	11.05	**5.56**	0.687	**0.557**	18.07	**6.20**	27.09	**6.19**
经典后端 0 dB	11.15	**6.32**	0.722	**0.580**	18.91	**7.81**	26.02	8.07
经典后端 -5 dB	14.36	**7.13**	0.773	**0.622**	25.75	**9.62**	41.38	10.32
回声/混响	6.09	4.87	0.564	**0.506**	7.31	**4.74**	7.42	**4.76**
二人重叠·中文	22.41	16.63	0.914	0.860	46.05	33.28	65.94	46.10
二人重叠·英文	9.13	7.76	0.648	0.602	13.82	10.65	18.64	13.27
三人重叠·中文	28.43	18.42	0.979	0.934	61.02	39.89	76.39	48.58

注:minDCF 为官方脚本输出(p_{tar}=0.01,c_{miss}=c_{fa}=1),工作点由 2001 阈值点分位数扫描得到。minDCF 与 EER 八格全部同向改善,但低误报口径下幅度小于 EER(主力 0dB −18% vs −41.7%)——minDCF 对分数尾部更敏感;固定 FAR=5% 时主力/经典/混响各格 FRR 降至 4.7~9.6%,重叠场景 FRR 仍高(三人重叠 39.9%),人声盲区在工作点口径同样可见。

6.4 噪声类型对比(域泛化)

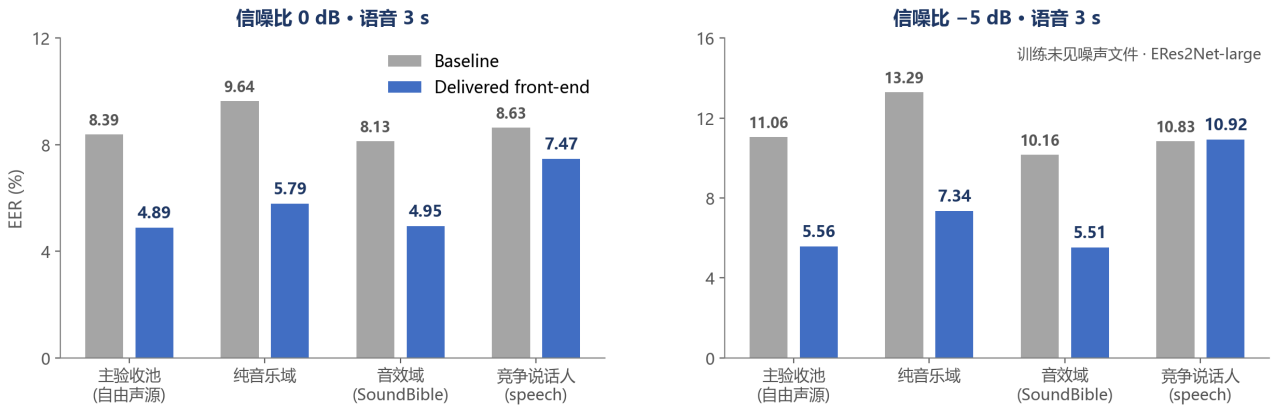


图 7 | 噪声域对比(换域噪声均为训练未见)

表 9 | 噪声域对比(域泛化)

噪声域	raw 0dB / -5dB	前端 0dB / -5dB	降幅	判读
主验收池(free-sound 后 20%,186 条)	8.39 / 11.06	4.89 / 5.56	**-41.7% / -49.7%**	主验收场景达标
纯音乐域	9.64 / 13.29	5.79 / 7.34	**-39.9% / -44.8%**	非人声全额迁移
音效域(soundbible)	8.13 / 10.16	4.95 / 5.52	**-39.1% / -45.7%**	同上
竞争说话人域(speech)	8.63 / 10.83	7.47 / 10.92	**-13.5% / +0.8%**	**结构性盲区**

注:非人声噪声 −39% 以上,主池结论非过拟合;人声干扰是结构性盲区——前端对"语音型干扰"的压制能力有限,与重叠场景增益偏低、附录 C 泄漏机理同根。

6.5 注册语音带噪鲁棒性(注册侧诊断)

验收条款只约束测试侧噪声;真实部署中**注册语音本身也可能带噪**。在 100 人代理验证集(训练/测试均未见过的说话人)上做注册侧 SNR {clean, 15, 10, 5, 0} dB × 测试侧 {0 dB, -5 dB} 全网格诊断:注册语音按 SNR 加噪后仍作为前端增强条件,交付前端(r5)增强后打分(冻结验证器口径;官方测试集冻结不重调,故诊断在代理集完成)。

表 10 | 注册语音带噪 × 测试带噪全网格(EER %)

注册语音质量	测试 0 dB		测试 -5 dB	
	raw	前端	raw	前端
干净注册	5.50	**1.81**	13.00	**3.74**
15 dB 注册	6.00	2.48	12.76	4.22
10 dB 注册	6.24	2.26	12.24	4.00
5 dB 注册	7.24	2.52	12.24	4.74
0 dB 注册	9.00	4.50	12.72	6.24

注:raw = 带噪注册嵌入直接对带噪测试语音打分(100 人代理验证集,产物 AI/8.27/diag_enroll_noise/)。注册质量下降时前端增益缓降但仍大幅有效——注册低至 0 dB 时相对降幅仍约 50%,部署时注册端不必苛求录音棚条件。

7 消融实验

7.1 增量消融(每级只加一个变量)

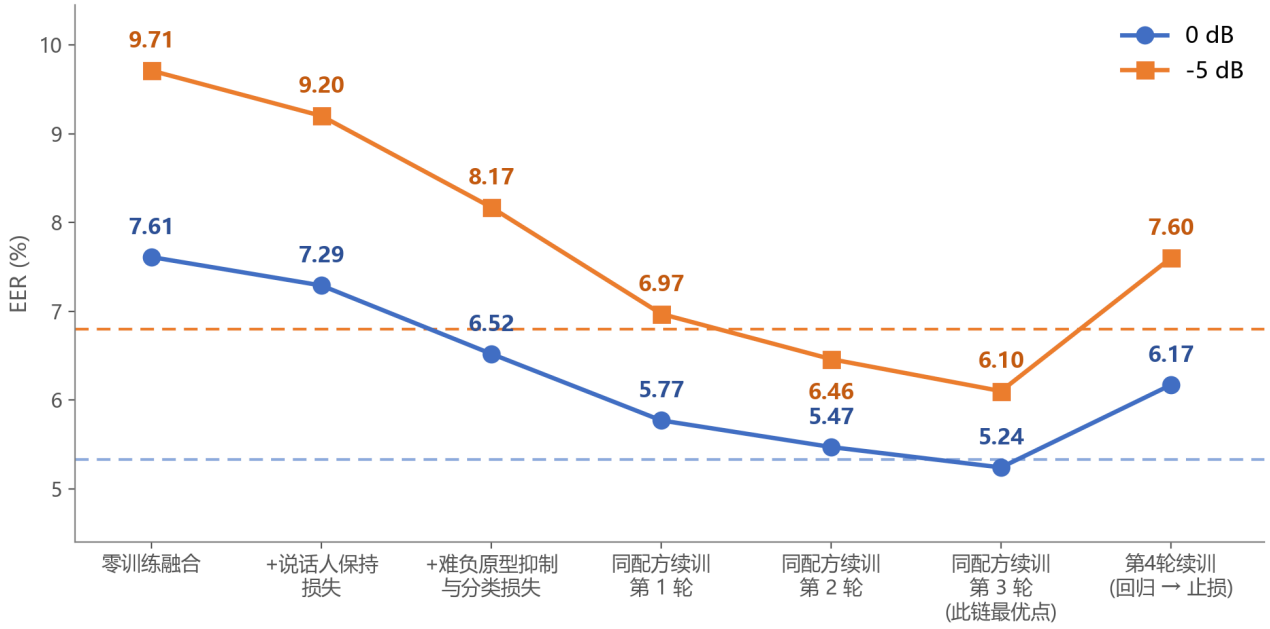


图 8 | 增量消融链(冻结验证器口径;虚线为该口径 30% 线)

两级损失各贡献 -4~-11%,难负原型抑制及同配方延长训练贡献最大(累计 -31.2%/-37.2%);第 4 轮过拟合回归(+17.7%),按预声明止损线停机。链路完整、可复现,详见 4.4 表 3。

7.2 单独消融 A:说话人保持损失系数

同基座同预算三臂(0.1/0.3/0.5),困难验证集(与官方负对同构)选点,3 轮:

表 11 | 说话人保持损失系数消融

λ_{spk}	困难验证集 avg	官方单次判决
0.1	7.750	未触发官方
0.3	**7.403(加速下行)**	**官方实测 7.293 / 9.202**
0.5	7.750	未触发官方

注:倒 U 形剂量响应,0.3 最优;官方增益落在预声明饱和带(<0.1-0.2pp)→ 不堆轮数,直接叠加下一级。

7.3 单独消融 B:难负原型抑制系数与原型池

表 12 | 难负原型抑制系数与原型池消融

变体	困难验证集(0dB/-5dB)	官方单次判决
λ_{ns} = 0.2	7.023(4.261/9.784)	未触发官方
λ_{ns} = 0.5	**6.881(4.045/9.716,单调未饱和)**	**官方实测 6.519 / 8.173**
原型池换成竞争说话人域定向	—	**官方实测 7.184 / 9.005(更差)**

注:与消融 A 相反,λ_{ns} 响应单调未饱和(支持继续加码);"最难"比"同域"重要——通用难例池优于同域定向池。

7.4 单独消融 C:前端 × 后端矩阵

表 13 | 前端增益的跨后端迁移(延长续训第 2 轮版前端)

后端	raw 0dB / -5dB	+前端 0dB / -5dB	降幅
ERes2Net-large	8.390 / 11.055	5.576 / 6.531	**-33.5% / -40.9%**
ECAPA-TDNN	11.148 / 14.358	7.185 / 8.399	**-35.5% / -41.5%**
ReDimNet2-B6	9.941 / 13.026	8.069 / 10.203	**-18.9% / -21.7%**

注:增益来自前端本身、可跨后端迁移,但在轻量后端的嵌入空间有所衰减——与其判别面性质有关(第 9 章)。

7.5 消融附带的方法学收获

- 困难验证集**方向全对**但**幅度高估约 5 倍**(预测 -0.27pp vs 官方实测 -0.089pp)→ 立下"困难集移动 <1pp 不动官方"铁律;
- 旧版随机验证集系统性乐观 +5.6/+4.7pp(负对过易),全部选点切到困难口径;
- "前 2 轮无增益、第 3 轮兑现"两次复现 → 趋势判决不早于 3 轮。

8 大、小模型与协同方案比较

任务书要求"比较大模型、小模型及协同方案"。同一协议下的横向对比如下(0dB/-5dB,3s):

表 14 | 大、小模型与协同方案比较(0dB/-5dB,3s)

方案	参数量	0dB	-5dB	说明
WavLM-base[10](大模型,SSL 预训练,零样本)	≈95M	**35.28**	**38.42**	英文域预训练 + 域不匹配,中文跨设备协议上远差于监督中小模型;clean 亦 27.77
WavLM-base(大模型,SSL,**中文 90k 多条件微调后**,9.3 补测)	≈101M	**20.90**	**24.01**	冻结 CNN 前端、transformer 全可训,7 轮;较零样本改善 11~14pp(clean 17.04),**但仍大幅落后于 29M 监督模型**——微调已把"不可用"拉回"可用",却无竞争力
ReDimNet2-B6(小模型)	12.7M	9.94	13.03	参数最小,性价比高,但增益迁移有所衰减
ECAPA-TDNN(中模型)	20.8M	11.15	14.36	
ERes2Net-large(主骨干)	29.1M	8.39	11.06	主验收靶子
五模型权重平均(协同,soup5)	29.1M	7.61	9.71	后用于训练期验证器
八成员异构融合(含 WavLM,协同)	—	7.21	9.15	融合系统历史最优;后被前端路线全面超越(同口径 5.24/6.10)
ERes2Net + 交付前端(本课题)	**+9.2M**	**4.89**	**5.56**	**全表最优**

注:①大模型零样本在本协议无优势,域匹配比模型大小更重要;②SSL 大模型经中文 90k 多条件微调后仍大幅落后于 29M 监督模型——当前中文数据规模下,域匹配与数据规模比参数量更关键;③协同方案(权重平均/异构融合)有稳定但有限的收益;④"中等骨干 + 注册条件化前端"性价比最高。

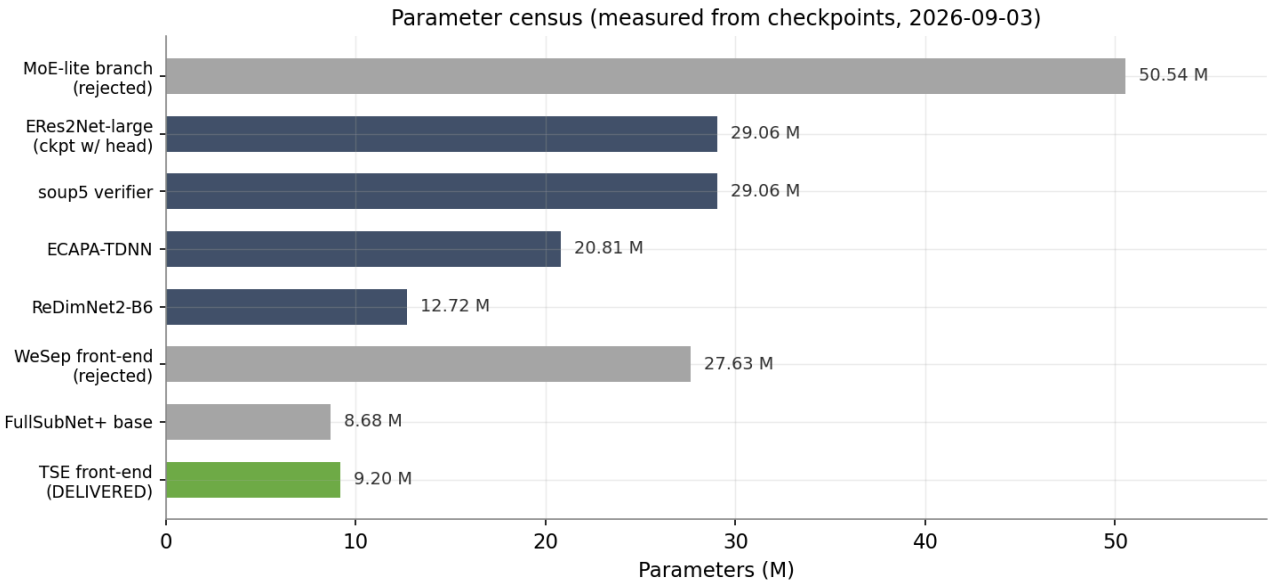


图 9 | 参数量普查(完整数据见附录 A)

9 局限性分析

1. **部署口径下的条件信息泄漏(主要局限)**:条件化增强会将注册身份信息写入输出语音;在部署真实口径(claim)下前端尚未超越未增强基线,15 种训练/推理侧补救刻画出清晰的权衡前沿、暂无方案双达标(分析与补救全景见附录 C)。验收口径的结果不受影响。
2. **人声干扰域盲区**:非人声噪声 -39% 以上,竞争说话人域 -13.5%/+0.8%;重叠场景 -15.0%~-35.2%,英文干扰仅 -15.0%。注册条件化是多人场景潜在的解决方向,但当前前端对"语音型干扰"的分离能力仍不足。
3. **1s 短语音未过线**:0dB 档 -26.9%,距 30% 线差约 3pp(时长增强后仍不足)。
4. **轻量后端增益衰减**:ReDimNet2-B6 -23.7%/-28.2%,差约 2pp。其嵌入判别面与前端优化目标(以 soup5/ERes2Net 系验证器定义)不一致。
5. **挑战目标未冲击**:EER ≤ 0.5% 与现有水平差一个数量级。9.3 补测的 WavLM 微调实验进一步表明单靠加大参数量不行——1.01 亿参数的 SSL 大模型经中文 90k 数据微调后仍大幅落后于 29M 监督模型;突破需更大规模中文域数据 + 多通道等根本性手段。
6. **评测规模限制**:加压检验(附录 C)的非目标侧为 30,000 条抽样(目标侧全量),CI95 ≈ ±0.2pp;更多样的冒认攻击方式(如跨设备冒认)未覆盖。

10 总结与展望

10.1 总结

- 建立了说话人隔离、开集验证、阈值冻结的统一评测体系,官方协议校准偏差 <0.6pp;
- 排除两条自然路线并定位机理(后端微调"增益不足不过线"、通用降噪"抹平身份"、"任务定义不当"),由此提出**注册条件化目标说话人提取前端**(9.2M 参数,VoiceFilter 式 FiLM 条件化 + 末层零初始化);
- 四级加码(说话人保持 → 难负原型抑制与判别分类 → 同配方延长续训至止损 → 时长增强)配合严格的代理选点/官方单次纪律,交付口径主力后端 **-41.7%/-49.7%**、经典后端 **-43.3%/-50.3%**,超额完成 ≥30% 验收线;clean 无退化,非人声域、混响、重叠、短语音全轴分项报告;
- 主动按部署真实口径加压复测,发现并系统刻画**注册条件泄漏机理**与 15 臂权衡前沿(附录 C)——本课题最重要的科学产出与开放问题。

10.2 展望

1. **注册条件泄漏修复**(现象与全景见附录 C):三个候选方向——①条件dropout/扰动训练(注册嵌入加噪、随机置换冒认条件并显式建模);②分数域校准(以冒认感知的打分归一替代分数融合);③改条件注入位置(仅在掩码估计端注入、输出端做身份中和);目标:部署口径优于 raw 的同时验收口径保住 -30%。
2. **人声干扰盲区**:引入重叠语音训练(utterance-mixing,如 WavLM 预训练所用)与说话人分离前端级联;注册条件从单嵌入扩展为"目标嵌入 + 干扰负原型"双条件。
3. **轻量后端适配**:以 B6 自身为验证器重训前端(匹配判别面),或在 B6 嵌入空间做蒸馏对齐。
4. **短语音**:注册侧多句拼接/质量加权模板 + 前端输出段的置信度加权打分。
5. **部署压缩**:前端 9.2M 已小,可进一步量化/蒸馏;条件提取与打分复用同一后端的架构天然省一次部署。

未来职业规划

结合本次实习课题的科研与工程训练,我的职业规划分三个阶段:

阶段	规划
短期 (硕士在读,1-2 年)	完成本课题交付与后续迭代;把注册条件泄漏机理、人声干扰盲区两个开放问题推进为论文成果(目标:说话人验证 / 语音增强方向会议或期刊);系统补齐语音大模型(SSL 预训练、多模态、流式部署)方向的工程能力。
中期 (毕业后 3-5 年)	进入工业界从事语音算法研发,专注声纹验证、语音识别与增强技术在智能终端、车载等场景的规模化落地;保持与学术界的连接,持续在开源社区输出可复现的工作。
长期 (5 年以上)	成长为能独立带方向的技术专家,深耕可信语音交互(鲁棒性、安全性、隐私保护);期望参与国产 AI 平台(如中国移动九天大模型生态)的语音能力建设,把课题中"从路线排除到交付"的方法论带进产业。

参考文献

[1] Reynolds D A, Rose R C. Robust text-independent speaker identification using Gaussian mixture speaker models[J]. IEEE Transactions on Speech and Audio Processing, 1995, 3(1): 72-83.

[2] Desplanques B, Thienpondt J, Demuynck K. ECAPA-TDNN: emphasized channel attention, propagation and aggregation in TDNN based speaker verification[C]//Interspeech 2020. 2020: 3830-3834.

[3] Hao X, Su X, Horaud R, et al. FullSubNet: a full-band and sub-band fusion model for speech enhancement[C]//ICASSP 2021. 2021: 6633-6637.

[4] Chen J, et al. FullSubNet+: channel attention FullSubNet with complex spectrograms for speech enhancement[C]//ICASSP 2022. 2022.

[5] Wang Q, Muckenheim H, Wilson K, et al. VoiceFilter: targeted speech separation by speaker-conditioned spectrogram masking[C]//Interspeech 2019. 2019: 2728-2732.

[6] Perez E, Strub F, de Vries H, et al. FiLM: visual reasoning with a general conditioning layer[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018: 3942-3951.

[7] Chen Y, Zheng S, Wang H, et al. An enhanced Res2Net with local and global feature fusion for speaker verification[C]//Interspeech 2023. 2023.

[8] Zheng S, Cheng L, Chen Y, et al. 3D-Speaker: a large-scale multi-device, multi-distance, and multi-dialect corpus for speech representation disentanglement[C]//Interspeech 2023. 2023.

[9] Deng J, Guo J, Xue N, et al. ArcFace: additive angular margin loss for deep face recognition[C]//CVPR 2019. 2019: 4690-4699.

[10] Chen S, et al. WavLM: large-scale self-supervised pre-training for full stack speech processing[J]. IEEE Journal of Selected Topics in Signal Processing, 2022, 16(6): 1505-1518.

附录 A 模型参数量普查

9.3 对全部 17 个 checkpoint 实测(脚本 census_params.py,口径:state_dict 浮点张量元素数;产物 params_census.json + 模型参数量统计.md):

表 15 | 参数量普查摘要

模型	参数量	文件	说明
FullSubNet+ TSE 前端(交付 r5)	**9.20M**	35.2MB	基座 8.68M + SpeakerFiLM 0.52M;全部补救臂同构 9.20M
FullSubNet+ 通用基座(8.18)	8.68M	33.2MB	条件化之前的形态
ERes2Net-large(主后端)	29.06M	111.0MB	ckpt 含分类头;嵌入提取器口径 22.46M
ECAPA-TDNN	20.81M	79.5MB	
ReDimNet2-B6	12.72M	48.8MB	
soup5 / soup_w50(权重平均)	29.06M	111.0MB	训练期冻结验证器
后端鲁棒微调系列(8.21-8.24 多配方)	29.06M	130.4MB(.tar 含优化器)	与原架构同构的权重变体(soup5 即由该系列权重平均而来)
ECAPA robust(镜像微调)	20.81M	86.7MB	第二后端交付
MoE-lite 支线(否决)	50.54M	212.4MB	+74% 参数无收益,硬成本证据
GateNet 支线(否决)	29.25M	131.1MB	+0.19M,增益不过判决线
WeSep 第三方前端(探索弃用)	27.63M	269.5MB(含优化器)	

注:**部署栈 = 前端 9.20M + 嵌入提取骨干 22.46M ≈ 31.7M ≈ 127MB(fp32)**,条件提取与打分复用同一后端。

附录 B 实验产物索引

内容	位置(服务器 /data/home/ligangrui/china_mobile/)
任务书	任务.xlsx;课题分析报告(AI/)
官方打分结果(逐格 EER/minDCF)	各实验目录 */result.metrics
交付终评全表 / 场景 / clean 基线	AI/8.28/final_eval_r5/、AI/8.28/scenes_r5/、AI/8.28/clean_baseline_eres2net_3s/
噪声域对比	AI/8.28/final_eval_r5/nd_r5_eres_*(前端)、AI/8.28/noise_domains/eval_raw/(锚点)
增量/剂量消融官方结果	AI/8.27/exp/official_*/;剂量判决记录 AI/8.27/README.md
claim 三口径与全部补救臂	AI/8.31/claim_retest/、AI/8.31/claim_fix/(summary/energy_gate/fusion)
ROC/DET 与固定工作点	AI/8.30/roc_det/(PNG+CSV+summary.json)、gen_roc_det.py
失败案例挖掘	AI/8.30/failures/failures.json、mine_failures.py
注册语音带噪鲁棒性诊断	AI/8.27/exp/proxy/diag_enroll_noise/summary.json
参数量普查	AI/9.3/census_params.py、params_census.json、模型参数量统计.md
clean 直测格(r5 前端增强 clean 测试集,9.3 补测)	AI/9.3/fe_clean/(launch_fe_clean.sh、fe_clean_eres_3s/result.metrics)
WavLM 微调版官方协议评测(9.3 补测)	AI/9.3/wavlm_ft_official/(wavlm_summary.json、scores/);微调训练 AI/8.24/wavlm_finetune.py、exp/wavlm_ft/
clean 基准三后端 × 三时长全格(9.4 补测)	AI/9.4/clean_bench/{ecapa,eres2net,redimnet2}/{1s,3s,5s}/(result.metrics、trials_*.score);打分脚本 AI/9.4/score_clean_bench.sh
汇总文档	AI/9.3/README_实验结果汇总.md、项目完整故事_9.3.md
交付 checkpoint	前端 AI/8.27/exp/tse_v3_ns05duraug_r5/checkpoint_best.tar;后端 AI/8.24/exp/soup5/
训练/评测代码	AI/8.26(tse_model.py、train_tse*.py)、AI/8.22(后端微调)、AI/8.27(exp/ 评测链)
交付材料汇集(报告/PPT/讲稿/图/清单)	AI/9.3/交付材料_9.3/(00-08 目录;本地 E 盘同步备份)

附注:周报(7.20-8.28 共 6 期)、开题报告与本报告数字一一对应;全部实验在 4×Tesla P100-PCIE-12GB 服务器完成,评测脚本可复现(seed 固定)。

附录 C 部署口径(claim)分析与局限性与补救全景

本附录为**部署口径的分析与局限性讨论**,不属验收主线:验收条款的场景设定(单说话人噪声下的声纹验证)中,测试语音与注册身份的绑定是协议给定条件,oracle 口径即任务验收口径(第 6 章交付大表)——当前结果已验证注册条件化增强能力。claim 口径是面向真实部署的主动加压检验,定位与汇报 PPT 的备用页一致,用于说明方法边界、防止部署误读:真实部署条件下,条件信息泄漏问题仍需进一步解决,这是本课题识别出的最重要的开放问题。

C.1 口径定义

- **raw**:不增强,注册语音 vs 带噪语音直接打分(基线锚点);
- **oracle 口径(交付口径)**:测试句按其**真实说话人**的注册语音做增强条件——系统"知道"这句是谁的;
- **claim 口径(部署真实口径)**:真目标句同 oracle;**冒认句按"声称者"的注册语音做条件**——部署时系统只知道对方**声称**的身份,冒认者会用别人的身份来攻击系统。

C.2 主结果与机理

表 16 | 交付前端三口径对比(0dB/-5dB,3s)

条件	raw	oracle(交付)	claim(部署)
0 dB	8.37	**4.88(-41.7% ✅)**	**10.72(比 raw 还差 +2.36pp ❌)**
-5 dB	11.09	**5.53(-50.1% ✅)**	**12.85(比 raw 差 +1.76pp ❌)**

注:抽样 = 全部 211,400 目标 + 30,000 非目标,bootstrap 200 次 95% CI ≈ ±0.2pp。

机理(冒认泄漏):冒认侧把冒认者的语音"往声称者拉"——非目标分数中位数从 0.044(raw)抬到 0.129(claim),约 3 倍,误接受随之上升。换言之,**注册身份信息经条件化增强"泄漏"进了增强语音本身**:前端不仅去噪,还在输出中写入了注册说话人的特征。该"对语音型干扰压制不足"的机理,与竞争说话人噪声域增益偏低(表 9)、重叠场景增益受限(表 7)一脉相承。

C.3 系统性补救实验(13 个训练侧臂 + 2 种推理侧)

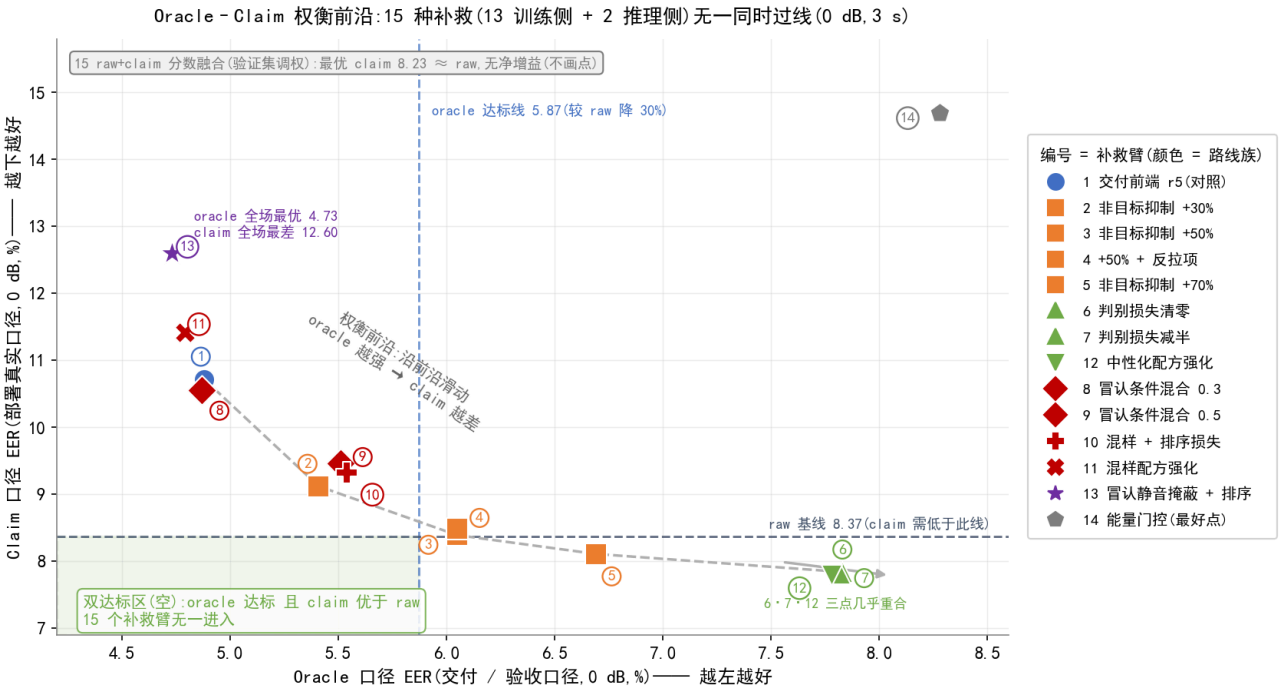


图 10 | oracle-claim 权衡前沿(0dB,15 臂;双达标区为空)

注:横轴交付(oracle)口径、纵轴部署(claim)口径;左下绿区为"双达标区"(oracle 过 30% 线且 claim 优于 raw)——该区为空,15 臂全部落在权衡前沿上,点旁编号对应表 17/18 各补救臂。

表 17 | 训练侧补救 13 臂全量结果

臂(在交付前端基础上改了什么)	oracle 0dB / -5dB	claim 0dB / -5dB	claim 冒认分中位
交付前端(对照)	4.88 / 5.53	**10.72 / 12.85**	0.129
难负原型抑制训练占比 +30%	5.41 / 6.20	9.12 / 10.98	0.100
+50%	6.05 / 7.14	8.39 / 10.25	0.082
+50% + 反拉项	6.05 / 7.14	8.48 / 10.32	0.082
+70%(claim 首次优于 raw)	6.69 / 8.30	**8.11 / 10.05**	0.069
判别损失清零(前端"中性化")	7.83 / 9.98	7.84 / 10.00	0.051
判别损失减半	7.82 / 10.02	7.82 / 10.03	0.050
训练混入冒认条件样本 40%(强度 0.3)	4.87 / 5.58	**10.56 / 12.35**	0.129
同上(强度 0.5)	5.51 / 6.52	9.46 / 11.29	0.104
混样 + 排序损失	5.54 / 6.49	9.33 / 11.13	0.103
混样配方强化版	4.79 / 5.48	**11.42 / 13.49**	0.140
中性化配方强化版	7.78 / 9.98	7.79 / 10.00	0.051
冒认静音掩蔽 + 排序损失	**4.73 / 5.39(oracle 全场最优)**	**12.60 / 14.64(claim 全场最差)**	0.154

注:冒认分中位数(raw ≈ 0.044)直接度量"泄漏"强度,与 claim 恶化程度单调一致。

表 18 | 推理侧补救

推理侧补救	结果
能量门控(按增强语音能量静音可疑段,门限 -60...-10dB 全扫描)	各门限 claim 恒劣于 oracle;最好点(-60dB,静音 9.8%)claim 14.69 vs oracle 8.28;静音比例升至 100% 双双归零——未恢复有效性能
raw + claim 分数融合(验证集网格搜权重)	最优 0dB 8.23 / -5dB 10.50——只回到 raw 附近,无净增益

C.4 结论

验收(oracle)口径两个主后端 -41.7%~-50.4% 超额达标,验证了注册条件化增强能力;部署(claim)口径下,15 种补救实验刻画出清晰的权衡前沿,**尚无方案同时满足"验收过线且部署优于基线"两项要求**。最优补救臂(难负原型抑制占比 +70%)部署口径已优于未增强基线(-3.1%/-9.3%),但验收口径退回 1.7pp 线外。该现象由"条件化增强写入注册身份"的结构性机理决定,是本课题识别出的最重要的开放问题(解决方向见第 10 章展望)。