中国移动研究项目 · 子课题一

通用降噪与注册条件化 TSE 的声纹特征对比

补 充 技 术 报 告

—— 面向声纹验证的降噪前端失效机理与指标分析 ——

张启元（中国科学院大学）

中国移动研究项目 • 子课题一

2026 年 10 月 17 日

本报告是原《多条件中文声纹识别与噪声鲁棒性增强》技术报告的补充分析。原报告已给出的任务背景、数据协议、TSE 结构与主 EER 结果不再重复；本报告只讨论这次新增的四路对比、指标口径、失效机理与结果索引。

目录

摘要

1　本补充报告的范围与结论

2　分析对象与新增口径

3　新增评测指标与公式

4　四路对比结果

5　失效机理：为什么原方法会坏

6　结果查看指南：wav、图、数据分别在哪里

7　面试速答与口径建议

附录 A　产物、参数与复现

附录 B　新增参考

摘要

本报告是原技术报告的**补充分析**，不重复原报告已经给出的任务背景、数据协议、TSE 网络结构与主 EER 结果。它只回答三个问题：

1. **为什么原通用 FullSubNet+ 降噪后，声纹 EER 反而变差？**
2. **原方法与注册条件化 TSE 在 embedding、时频、信号/感知指标上到底差在哪里？**
3. **这些指标怎么定义、结果在哪里查、面试怎么讲？**

> **一句话结论：**原 FullSubNet+ 在 SI-SDR、全局 SNR、STOI 等“降噪/可懂度”指标上更好，却把 ERes2Net 的说话人 embedding 推离了 clean 的说话人流形；因此 EER 从 8.39% 升到 10.11%，比不处理还差。注册条件化 TSE 不是更“干净”的降噪器，但它是身份条件化的前端，target 分数、embedding 和 EER 全面改善（4.89%）。

关键数字：EER 8.391 → 10.113 → 4.892；target 0.422 → 0.391 → 0.471；同句 embedding 漂移 0.820 → 0.714 → 0.816（Noisy → 原方法 → TSE，0 dB）。完整四路对比表见 4.1。

本报告不重复：任务背景与验收要求、3D-Speaker 数据与 trial 协议、ERes2Net 三后端、TSE 的训练细节、主 EER 交付大表——这些均见原技术报告《多条件中文声纹识别与噪声鲁棒性增强》。

1　本补充报告的范围与结论

1.1 原报告已经回答什么，本补充新增什么

原技术报告《多条件中文声纹识别与噪声鲁棒性增强》已经完整给出了任务背景、3D-Speaker 数据与 trial 协议、ERes2Net 三后端、TSE 的网络结构与训练方法，以及主 EER 交付大表。这些内容本报告**不再重复**；需要时请直接查阅原报告对应章节。

原报告已有（本报告不重复）	本补充报告新增
任务目标、验收线、数据与噪声协议	clean / Noisy / 原 FullSubNet+ / TSE **四路同句对比**
ERes2Net 三后端、注册/trial 协议、EER/minDCF 定义	**embedding 漂移**、target/gap/d′ 的逐句分析
TSE 的 FiLM 结构、四项损失、训练与消融	SI-SDR / 全局 SNR / VAD-SNR / PESQ / STOI **新增指标**
主 EER 交付大表与 claim 口径分析	“为什么通用降噪会让 EER 变差”的**机理分析**
论文/答辩用的主结果与结论	时频/谱形证据、结果查看索引、面试口径

1.2 结论摘要

原 FullSubNet+ 是一个**无注册条件的通用降噪器**：它把带噪语音往“clean 波形”方向重建，但不负责“保留谁”。在这批跨设备中文语音上，它确实让波形更接近 clean（SI-SDRi +8.59 dB、STOI +0.096、PESQ +0.584），却把 ERes2Net 的说话人 embedding 推离了 clean 的说话人流形（同句余弦 0.820 → **0.714**），导致 target 分数下降（0.422 → 0.391）、target−nontarget gap 收窄（0.371 → 0.332）、EER 从 8.391% 升到 **10.113%**。

注册条件化 TSE 的波形指标并不全面占优（SI-SDRi +7.62 dB、STOI 0.739，均略低于原方法），但它的 embedding 留在说话人流形附近（余弦 0.816），target 分数升到 **0.471**，EER 降到 **4.892%**。这说明：**“降噪指标更好”不等于“声纹前端更好”**；声纹验证需要的是身份保持，不是波形保真。

> **本报告最想让你记住的三个数字：** 0.714（原方法 embedding 到 clean 的余弦，比 Noisy 的 0.820 还低）；10.113%（原方法 EER，比不处理还差）；4.892%（TSE EER）。它们分别对应“embedding 被推远”“验证变差”“身份条件化修复”三步。

1.3 阅读顺序

1. 想快速知道“做了什么、结论是什么”：看本节 + 4.7 小结。
2. 想弄清指标口径（尤其三个 SNR）：看 3.3、3.4、3.8。
3. 想看证据：看 4.1–4.6 的表和图；想听声音/查更多数字：看第 6 节。
4. 面试前：看第 7 节的三句话版本与 Q&A。

2 分析对象与新增口径

2.1 沿用原报告、不重复的部分

本报告沿用原报告的 3D-Speaker 跨设备中文测试集、clean 注册、官方 1,378,206 条 trial、ERes2Net-large 后端与 EER/minDCF 定义；这些协议细节与数据划分见原报告第 2–3 章，主 EER 大表见第 6 章，本文不再重复。TSE 的网络结构、FiLM 注入与四项损失见原报告第 5 章；本文只在第 5 节解释“为什么它能保住 embedding”，不重新介绍模型。

2.2 本报告新增的四路条件

条件	具体内容	本报告用途
Clean	干净测试语音，作为参考上界	PESQ/STOI 的参考、embedding 漂移的锚点
Noisy 0 dB / −5 dB	clean + 噪声，输入混合 SNR 为 0 / −5 dB	对照基线；−5 dB 只补充 EER 与全局 SNR
FullSubNet+（原方法）	通用 cIRM 降噪；无注册条件；输出峰值归一化到 0.8	失效分析的主角
TSE（现有方法）	注册条件化 FullSubNet+；FiLM + 说话人保持 + 难负原型抑制；r5 版	身份条件化的对照

两个前端后接同一个冻结的 ERes2Net-large；因此 EER/embedding 差异来自前端增强后的语音，而不是后端变化。原方法的 checkpoint、增强 wav、embedding 与 TSE 的对应产物路径见附录 A；所有数字均来自这些原始产物，没有重训或重跑降噪。

2.3 本报告的分析子集

子集	规模	用途
全部测试句	8,507 条 / 1,378,206 trial	EER、target、gap、d′、embedding 漂移
随机子集	120 条（种子 2026）	SI-SDR / 全局 SNR / VAD-SNR / PESQ / STOI / 谱形统计
展示样本	5 条	试听、时频图、embedding 轨迹、逐句指标
PESQ-SNR 扫描	20 条	解释 0 dB 下 PESQ 的绝对量级

主分析条件是 0 dB；−5 dB 只补充 EER 与“降噪后全局 SNR”，用于回答“相对于原来的 0 / −5 dB 噪声数据，SNR 提升了多少”。EER 的完整交付主表仍以原报告为准；本报告 4.1 的总表只作为四路对比的阅读背景。

3 新增评测指标与公式

EER、minDCF、FAR/FRR、trial 协议在原报告中已有完整定义与主结果，本文**不重复**。下面只列本报告新增或重点使用的指标：它们回答的是“增强后的语音在信号、感知、身份三个层面发生了什么”，而不是重新评价主系统。

3.1 Embedding 余弦、target 分数与 embedding 漂移

ERes2Net 把每条语音映射成 512 维单位向量。两个 embedding 的余弦相似度衡量“像不像同一个人”：

$$s(\mathbf{a},\mathbf{b}) = \frac{\langle \mathbf{a},\mathbf{b}\rangle}{\|\mathbf{a}\|_2\|\mathbf{b}\|_2} \tag{1}$$

对测试语音 t，用同说话人的 clean 注册语音得到注册 embedding 均值 e_{enr}，target 分数为 $s_t = \cos(e_t,\ e_{\text{enr}})$。同时把同句在 clean 与增强条件下的 embedding 做余弦，得到 **embedding 漂移** d_t：

$$s_t = \cos\left(\mathbf{e}_t,\mathbf{e}_{\text{enr}}\right), \qquad d_t = \cos\left(\mathbf{e}_t^{\text{cond}},\mathbf{e}_t^{\text{clean}}\right) \tag{2}$$

target 分数越高，说明越像注册者；漂移越接近 1，说明增强后 ERes2Net 仍把这句话放在原来的说话人位置。两者一个看“注册相似度”，一个看“增强把 embedding 挪了多远”，本报告同时报告。

3.2 SI-SDR 与 SI-SDRi

SI-SDR 把估计信号 ŝ 分解为“clean 的最优缩放副本 + 残差”：

$$\hat{\mathbf{s}} = \alpha\mathbf{s} + \mathbf{e}, \qquad \alpha = \frac{\langle \hat{\mathbf{s}},\mathbf{s}\rangle}{\langle \mathbf{s},\mathbf{s}\rangle} \tag{3}$$

$$\text{SI-SDR} = 10\log_{10}\frac{\|\alpha\mathbf{s}\|_2^2}{\|\hat{\mathbf{s}} - \alpha\mathbf{s}\|_2^2} \tag{4}$$

$$\text{SI-SDRi} = \text{SI-SDR}(\hat{\mathbf{s}}) - \text{SI-SDR}(\mathbf{x}) \tag{5}$$

SI-SDR 是**尺度不变**的：整体音量不影响数值；残差 e 包含残余噪声、语音失真、增强伪影与对齐误差。对纯加噪输入，SI-SDR 近似输入 SNR；对增强后，它衡量“离 clean 有多远”。SI-SDRi 是相对带噪输入的提升，单位 dB，越高越好。

3.3 全局 SNR：与输入同电平的残差比

输入混合 SNR 是 clean 与噪声的能量比：

$$\text{SNR}_{\text{in}} = 10\log_{10}\frac{\|\mathbf{s}\|_2^2}{\|\mathbf{x} - \mathbf{s}\|_2^2} \tag{6}$$

对增强后的信号，直接算“clean 能量 / 残差能量”会遇到增益陷阱：原 FullSubNet+ 把输出峰值归一化到 0.8，整体增益比 clean 高约 20 dB；不匹配电平会得到无意义的负 SNR。因此本报告先把增强输出缩放到与带噪输入相同的整体 RMS，再算：

$$\beta = \frac{\|\mathbf{x}\|_2}{\|\hat{\mathbf{s}}\|_2}, \qquad \mathrm{SNR}_{\mathrm{out}} = 10\log_{10}\frac{\|\mathbf{s}\|_2^2}{\|\beta\hat{\mathbf{s}} - \mathbf{s}\|_2^2} \tag{7}$$

$$\Delta\mathrm{SNR} = \mathrm{SNR}_{\mathrm{out}} - \mathrm{SNR}_{\mathrm{in}} \tag{8}$$

其中 $\beta = \|x\|_2 / \|\hat{s}\|_2$。这样带噪基线就是它原本的输入 SNR（0 dB 数据实测 0.16 dB，−5 dB 实测 −4.53 dB），增强后的数值与它同电平可比。报告中的“全局 SNR 提升”均指这个 ΔSNR。

> **三个 SNR 不要混：**你最初设置的 0 / −5 dB 是**输入混合 SNR**；SI-SDR 是**尺度不变的全参考失真比**；本文的 VAD-SNR 是**分段语音帧/噪声帧功率比**。同一批 noisy 数据上实测：0 dB 数据的全局 SNR 0.16 dB、SI-SDR −0.52 dB、VAD-SNR 5.03 dB；−5 dB 数据分别为 −4.53 / −5.52 / 3.06 dB。VAD-SNR 的绝对值本来就不等于输入 SNR，不能把“VAD-SNRi +15.67 dB”加到 0 dB 上当作输出 SNR。

3.4 VAD 分段 SNR

先用帧能量：

$$e(n) = \frac{1}{W}\sum_{k=0}^{W-1} s^2(n+k) \tag{9}$$

用 clean 的帧能量选出语音帧 S（能量最高 60%）与噪声帧 N（最低 20%），再在同一信号内算语音帧平均功率与噪声帧平均功率之比：

$$\mathrm{SNR}_{\mathrm{VAD}} = 10\log_{10}\frac{\frac{1}{|S|}\sum_{n\in S}\hat{s}^2(n)}{\frac{1}{|N|}\sum_{n\in N}\hat{s}^2(n)} \tag{10}$$

它衡量“语音段相对噪声段高多少”，对噪声底抑制敏感，但不惩罚语音失真；因此通常比全局 SNR 高很多。正确用法是在同一定义下比较不同前端，例如原方法 20.69 dB、TSE 13.43 dB，而不是拿它和 0 / −5 dB 直接换算。

3.5 PESQ-WB

PESQ 是 ITU-T P.862 的全参考感知质量指标，16 kHz 版本为 P.862.2（PESQ-WB）。流程是：电平对齐 → IRS 滤波 → 时间对齐 → Bark 域感知变换 → 对称/非对称扰动 → 聚合 → MOS-LQO 映射。可用下面的框架理解：

$$D_{\mathrm{sym}}(f,t) = \left|L_X(f,t) - L_Y(f,t)\right| \tag{11}$$

$$D_{\mathrm{asym}}(f,t) = \max\left(D_{\mathrm{sym}}(f,t) - m(f,t), 0\right) \tag{12}$$

$$\mathrm{PESQ} = f_{\mathrm{MOS}}\left(\mathcal{A}\left[D_{\mathrm{sym}}, D_{\mathrm{asym}}\right]\right) \tag{13}$$

L_X、L_Y 是 Bark 频带响度；D_{sym} 是对称扰动，D_{asym} 是对“参考有、待测没有”的成分加罚；$\mathcal{A}$ 是时间/频带聚合，f_{MOS} 是标准映射。精确常数由 ITU-T P.862 规定，没有简单闭式公式。

PESQ 范围约 −0.5 – 4.5（本报告用官方 `pesq` 0.0.4，clean-vs-clean 为 **4.644**），而且**非线性**：1.3 → 1.9 不是“28% → 41%”。0 dB 下 PESQ 1.3 – 2.0 是正常量级；本数据 20 dB 也只有 3.18。请看同条件下的相对提升，不要拿它对 clean 的 4.644 做百分比。

3.6 STOI

STOI 在 1/3 倍频带上比较短时包络的归一化相关：

$$d_{j,m} = \frac{\sum_n \left(x_{j,m}(n) - \bar{x}_{j,m}\right)\left(y_{j,m}(n) - \bar{y}_{j,m}\right)}{\sqrt{\sum_n \left(x_{j,m}(n) - \bar{x}_{j,m}\right)^2}\sqrt{\sum_n \left(y_{j,m}(n) - \bar{y}_{j,m}\right)^2}} \tag{14}$$

$$\mathrm{STOI} = \frac{1}{JM}\sum_{j=1}^{J}\sum_{m=1}^{M} d_{j,m} \tag{15}$$

范围 0 – 1，越高越好；比 PESQ 更“线性”、更少饱和，但同样衡量可懂度/包络保真，不是说话人身份。标准实现还会对相关值做裁剪/归一化，具体以原文和 `pystoi` 为准。

3.7 d′ 与 shape RMSE

d′ 衡量 target 与 nontarget 两个分数分布的分离度：

$$d' = \frac{\mu_{\text{target}} - \mu_{\text{nontarget}}}{\sqrt{\frac{1}{2}\left(\sigma^2_{\text{target}} + \sigma^2_{\text{nontarget}}\right)}} \tag{16}$$

d′ 越大，两个分布越分开。shape RMSE 用 80 维 log-mel 谱形衡量增强后“精细谱包络”离 clean 多远：

$$X_{\mathrm{dB}}(m,t) = 10\log_{10}\left(\sum_k |X(k,t)|^2 H_m(k)\right) \tag{17}$$

$$\mathrm{RMSE}_{\text{shape}} = \sqrt{\frac{1}{|\Omega|}\sum_{(m,t)\in\Omega}\left[\left(X^{\text{cond}}_{\mathrm{dB}}(m,t) - X^{\text{clean}}_{\mathrm{dB}}(m,t)\right) - \bar{\Delta}\right]^2} \tag{18}$$

其中 Ω 是 clean 的活跃时频点，$\bar{\Delta}$ 是整体偏移；去掉偏移后只看谱形。shape RMSE 越低，谱形越接近 clean；它和 embedding 漂移有较强相关性（本报告 360 个“语句×条件”点 r = −0.54），是解释“为什么声纹会坏”的中间层证据。

3.8 指标对照与报告建议

指标	衡量什么	能否与输入 SNR 直接比	本报告用途
target / gap / d′	注册相似度与分布分离度	否	验证层面的直接证据
embedding 漂移	增强后 embedding 离 clean 多远	否	解释“为什么 EER 变差”
SI-SDRi	尺度不变的全参考失真比	带噪时近似；增强后不是	信号保真
全局 SNR Δ	与输入同电平后的残差比	是（本文定义）	回答“SNR 提升多少”
VAD-SNRi	语音帧/噪声帧功率比	否（绝对值不可比）	噪声底抑制
PESQ-WB / STOI	感知质量 / 可懂度	否	说明“降噪器更好 ≠ 声纹更好”
shape RMSE	谱形误差（去整体偏移）	否	连接频谱畸变与 embedding 漂移

4　四路对比结果

本节只报告本补充新增的对比；EER 的完整交付表、三后端结果与 claim 口径见原报告。为便于阅读，4.1 保留四路 EER 作为对比背景，后面的表格/图才是本报告新增的分析。

4.1 四路总表

条件（0 dB）	EER (%)	target 均值	target−nontarget	d′	同句 cos 到 clean	SI-SDRi (dB)	全局 SNR Δ (dB)	PESQ-WB	STOI
Clean	5.293	0.490	0.431	3.322	1.000	—	—	4.644	1.000
Noisy	8.391	0.422	0.371	2.752	0.820	0	0	1.305	0.654
FullSubNet+（原）	10.113	0.391	0.332	2.544	0.714	+8.59	+3.80	1.889	0.750
TSE（现有）	4.892	0.471	0.418	3.416	0.816	+7.62	+3.32	1.958	0.739

EER/target/gap/d′ /drift 覆盖 8,507 条测试句、1,378,206 条 trial；SI-SDRi/全局 SNR/PESQ/STOI 覆盖 120 条随机测试句。EER 的完整主表见原报告；本表只用于四路对比。

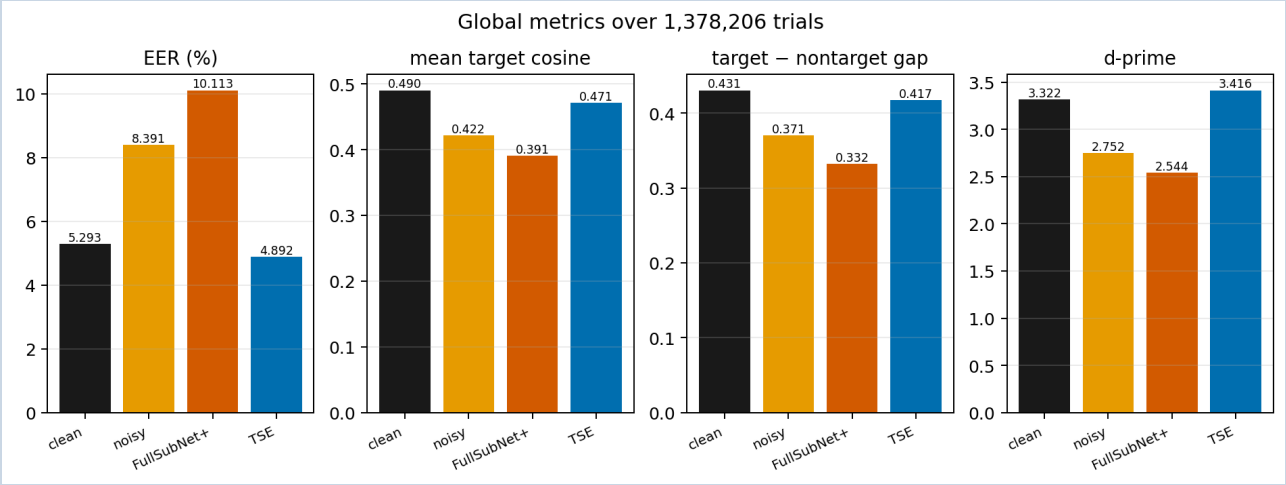


图 4-1　EER、target 均值、target−nontarget gap、d′ 四联图。原方法在四个指标上全面劣于 Noisy；TSE 全面优于 Noisy，且 EER/d′ 优于 Clean。

在 8,507 条测试句中，70.7% 被原方法拉低 target 分数；TSE 相对原方法恢复了 91.7%，相对 Noisy 恢复了 85.8%。原方法不是个别样本翻车，而是系统性地把 embedding 推向错误方向。

4.2 分数分布与 embedding 漂移

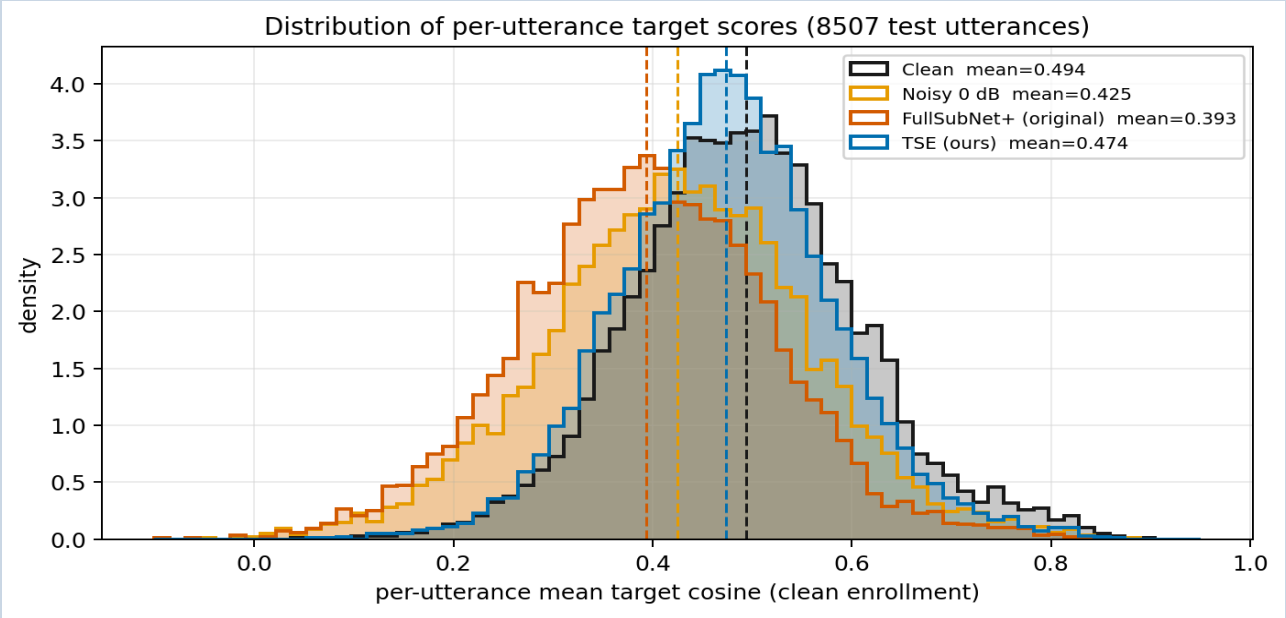


图 4-2　8,507 条测试语音的逐句 target 分数分布。原方法整体左移（均值 0.393），Noisy 为 0.425，TSE 右移到 0.474。

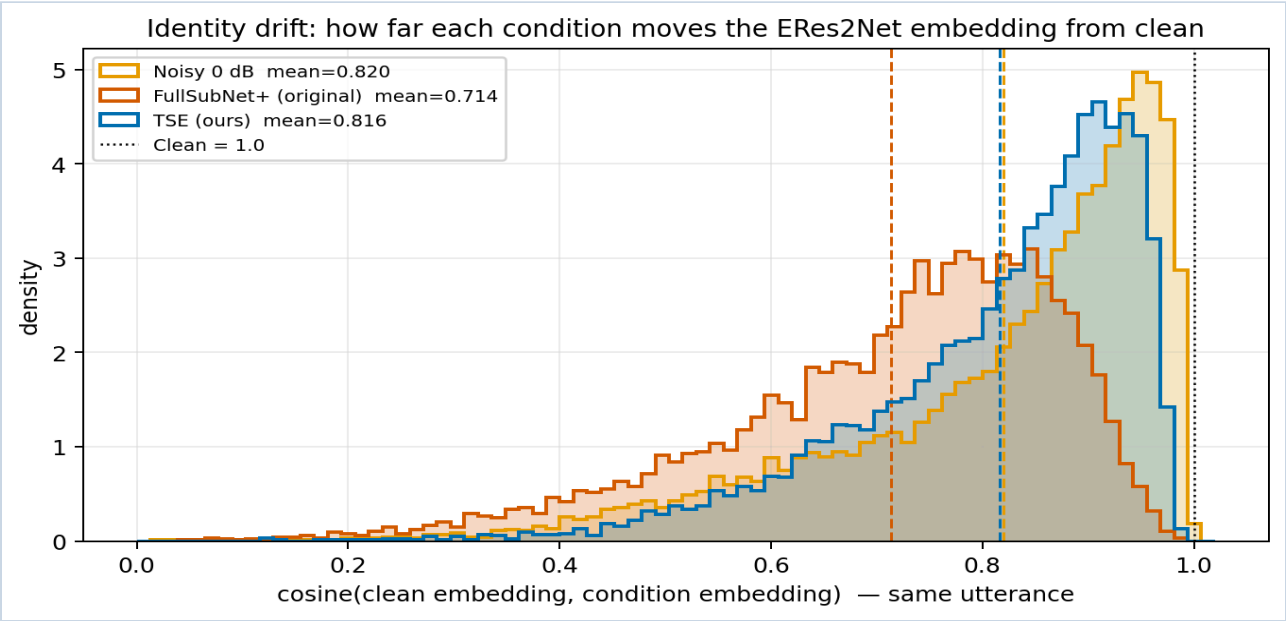


图 4-3　同一句 clean 与各条件 embedding 的余弦。原方法均值 0.714，Noisy 0.820，TSE 0.816；原方法比“完全不处理”还远。

图 4-2 与图 4-3 是同一件事的两个视角：target 分数回答“像不像注册者”，漂移回答“增强把这句话挪了多远”。原方法在两个视角上都变差；TSE 的漂移与 Noisy 接近，但 target 明显更高，说明它把测试语音往“注册的这个人”方向拉，而不是简单复刻 clean。

4.3 五条展示样本

#	测试语句	Clean	Noisy	FullSubNet+	TSE	试听
1	3D_SPK_06975_005_Device03...	0.662	0.534	**0.173**	0.593	文件夹
2	3D_SPK_06868_001_Device04...	0.746	0.436	**0.175**	0.591	文件夹
3	3D_SPK_06979_001_Device02...	0.603	0.460	**0.148**	0.499	文件夹
4	3D_SPK_06811_006_Device04...	0.637	0.415	**0.136**	0.494	文件夹
5	3D_SPK_06182_009_Device03...	0.570	0.441	**0.157**	0.494	文件夹

数字为与 clean 注册语音的平均余弦（官方 trial 口径）。5 条样本都呈现“Noisy 能认对 → 原方法掉到 0.13–0.18 → TSE 恢复到 0.49–0.59”。试听打开 listen.html，或进入文件夹的 `clean.wav / noisy_0db.wav / fullsubnetplus.wav / tse.wav`。

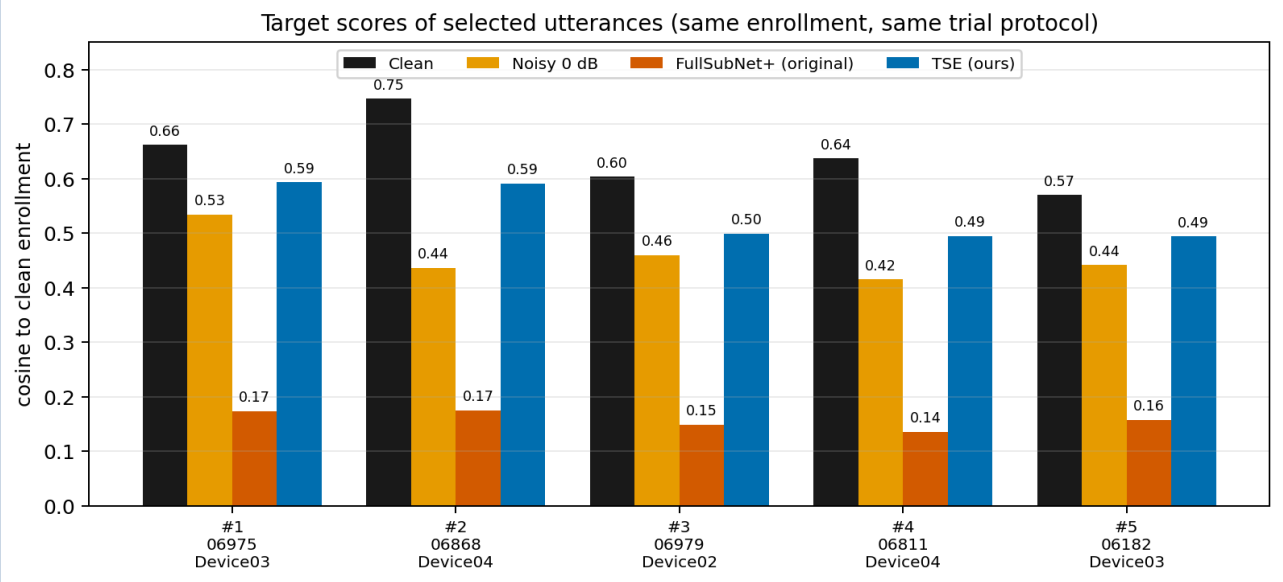


图 4-4　5 条展示样本的四路 target 分数。原方法在每条样本上都从 Noisy 的 0.42–0.53 掉到 0.14–0.18；TSE 恢复到 0.49–0.59。

这 5 条的信号指标同样值得注意：原方法的 SI-SDRi / VAD-SNRi / ΔPESQ / ΔSTOI 往往比 TSE 更好，但 target 更低。例如样本 1：原方法 +4.23 / +2.36 / +0.119 / +0.182，target 0.173；TSE +3.44 / +1.28 / +0.095 / +0.107，target 0.593。逐句数据见 `data/selected_intrusive_metrics.csv`。

4.4 信号与感知指标（120 条随机样本）

条件	SI-SDR (dB)	VAD 分段 SNR (dB)	PESQ-WB	STOI
Clean（参考）	—	—	4.644	1.000
Noisy 0 dB	−0.52	5.03	1.305	0.654
FullSubNet+（原）	8.07	20.69	1.889	0.750
TSE（现有）	7.09	13.43	1.958	0.739

条件	SI-SDRi (dB)	VAD-SNR 提升 (dB)	ΔPESQ	ΔSTOI
FullSubNet+（原）	+8.59	+15.67	+0.584	+0.096
TSE（现有）	+7.62	+8.40	+0.653	+0.085

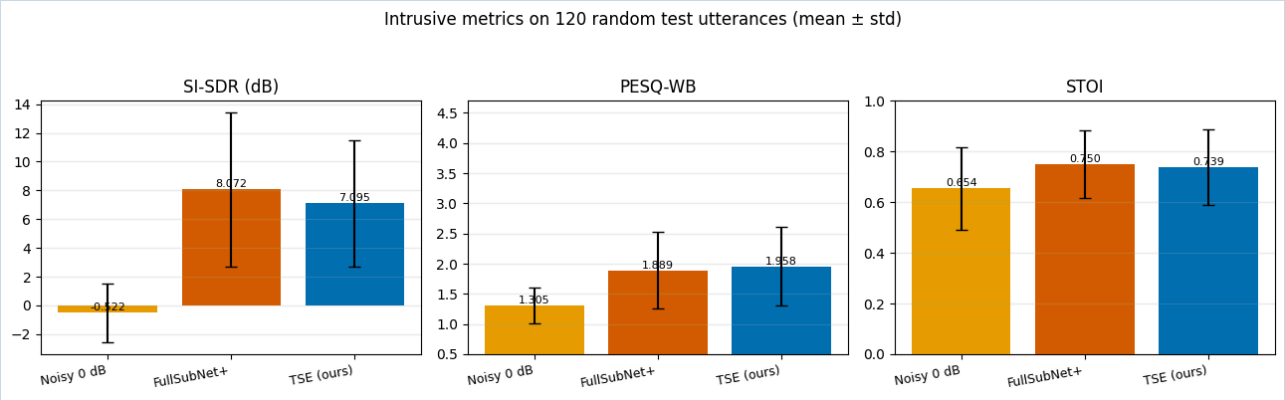


图 4-5　120 条随机样本的 SI-SDR / PESQ-WB / STOI（mean ± std）。原方法 SI-SDR、STOI 更高；TSE PESQ 略高。三项信号/感知指标与 EER 方向相反。

逐句改善比例：原方法 PESQ 85.8%、STOI 87.5%、SI-SDR 95.8%、VAD-SNR 99.2%；TSE 分别为 99.2%、95.0%、96.7%、95.0%。TSE 在 PESQ 上更稳定，但均值上原方法在 SI-SDR/SNR/STOI 更高。原方法更像“更好的降噪器”，但不是“更好的声纹前端”。

为什么 PESQ 离 clean 这么远

输入 SNR	20 dB	10 dB	5 dB	0 dB	−5 dB	Clean
PESQ-WB	3.18	2.15	1.69	1.32	1.19	4.644
STOI	0.925	0.832	0.762	0.660	0.593	1.000

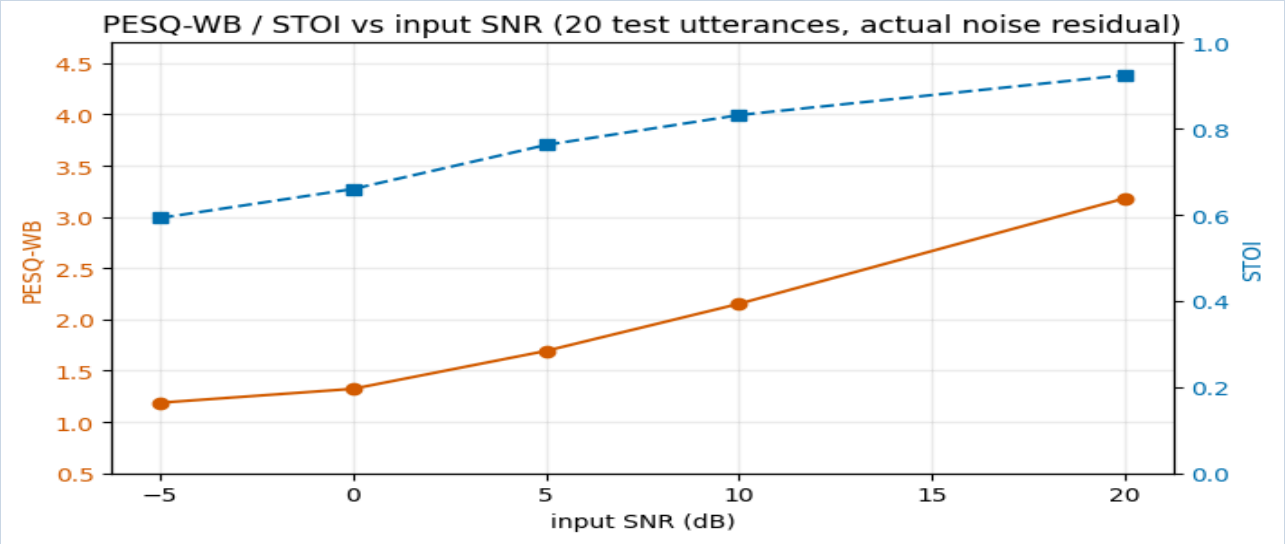


图 4-6　PESQ-WB / STOI 随输入 SNR 的变化（20 条测试语音，实际噪声残差）。0 dB 下 PESQ ~1.3 是正常量级；20 dB 也只有 3.18，4.644 是“完全相同”的上限。

结论： 0 dB 下 PESQ 1.3–2.0 并不奇怪；PESQ 是非线性、全参考指标，4.644 只对 clean-vs-clean 成立。实际 noisy 的 PESQ 1.333，与 0 dB 扫描点 1.323 吻合；120 条主统计的全局输入 SNR 为 0.16 dB。报告应看同条件下的相对提升。

4.5 降噪后数据的全局 SNR（0 dB / −5 dB）

按 3.3 的“与输入同电平”口径：把每个条件的输出缩放到与带噪输入相同的整体 RMS，再算相对 clean 的残差 SNR；带噪基线就是它原本的输入 SNR。

数据	Noisy	FullSubNet+	Δ vs Noisy	TSE	Δ vs Noisy
0 dB	0.16	3.96	+3.80	3.48	+3.32
−5 dB	−4.53	−1.37	+3.16	−1.96	+2.57

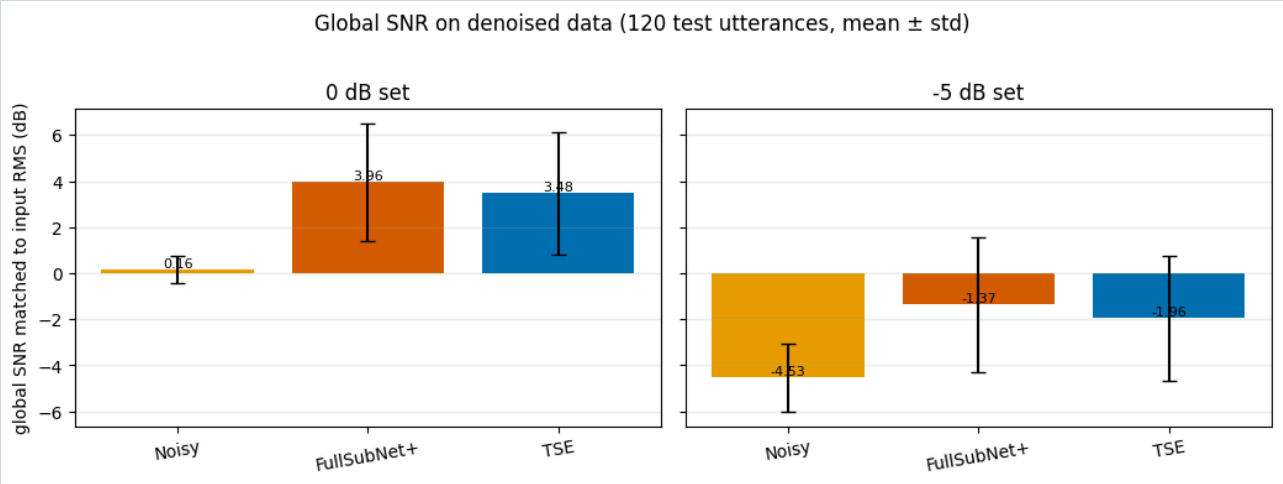


图 4-7　降噪后数据的全局 SNR（与输入同电平）。0 dB：0.16 → 3.96 / 3.48；−5 dB：−4.53 → −1.37 / −1.96。

作为对照：0 dB 下 SI-SDR 从 −0.52 到 8.07（原方法，+8.59）/ 7.09（TSE，+7.62）；VAD-SNR 从 5.03 到 20.69（+15.67）/ 13.43（+8.40）。三个数字不同不是矛盾，而是三个口径。

增益陷阱： 未做电平匹配的 raw 全局 SNR 对原方法是 −18.1 dB，不是“降噪把语音弄坏了 18 dB”，而是峰值归一化（0.8 × enhanced / max|enhanced|）带来的约 +20 dB 增益差；TSE raw 为 5.82 dB。不同增益的增强输出必须先电平匹配再比。

4.6 谱形证据：原方法改了什么

条件（120 条，0 dB）	low 20–500 Hz	mid 0.5–2 kHz	high 2–7.6 kHz	谱倾斜	RMS 增益	SI-SDR	shape RMSE	平均 dB 差
Clean	0.692	0.281	0.027	−25.1	−33.5 dBFS	—	—	—
Noisy	0.549	0.285	0.166	−18.9	+2.6 dB	−0.52	3.97	+1.35
FullSubNet+（原）	0.682	0.300	0.018	−28.2	+19.7 dB	8.07	7.19	+15.42
TSE（现有）	0.600	0.364	0.036	−22.2	−4.4 dB	7.09	3.89	−4.29

low/mid/high 为频带能量占比；谱倾斜越负=高频衰减越强；shape RMSE 为去掉整体偏移后的 log-mel 谱形误差；RMS 增益相对 clean。

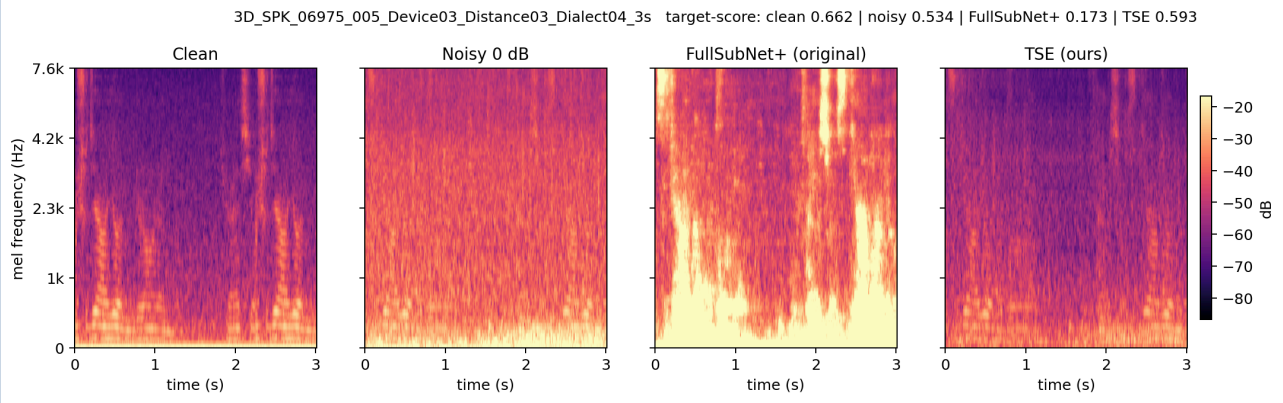


图 4-8　样本 1 的四路 log-mel 时频图。原方法（第三格）在低频/宽带出现明显能量抬升，高频细节被压暗；TSE（第四格）更接近 clean 的谱形。

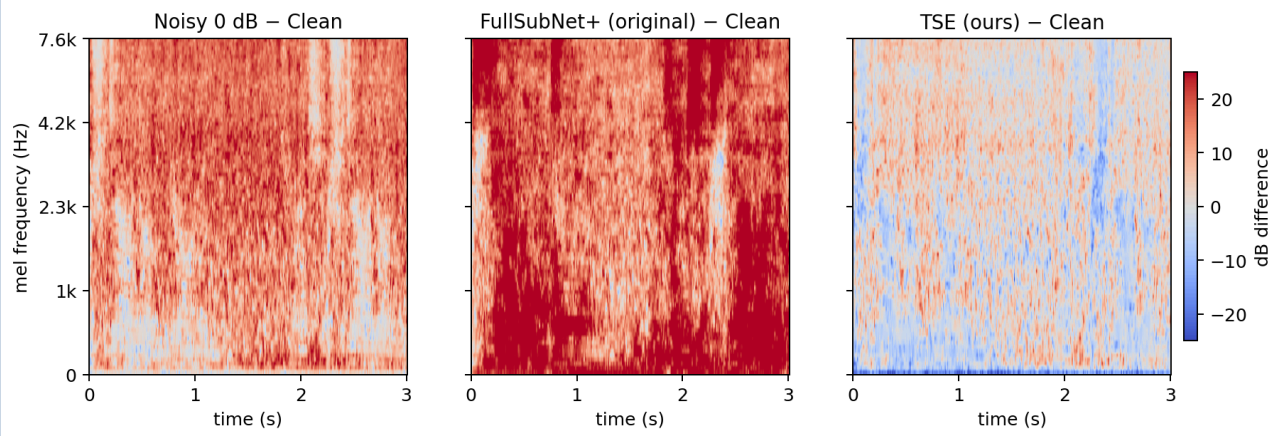


图 4-9　Noisy / 原方法 / TSE 分别减去 clean 的时频差（红=能量更高，蓝=更低）。原方法整体偏红并在高频出现负差；TSE 差异更小、更均匀。

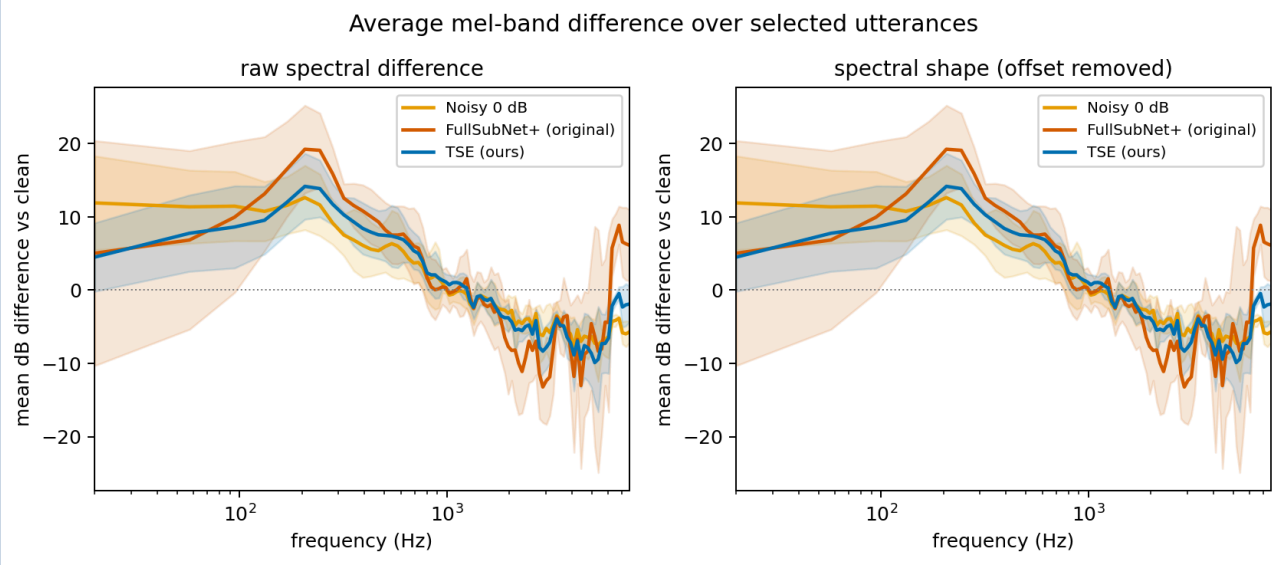


图 4-10　各频带相对 clean 的平均 dB 差（左：原始；右：去掉整体偏移）。原方法低频/中低频抬升、高频压低；TSE 更平。

原方法把 high 频带能量占比从 Noisy 的 0.166 压到 0.018（clean 0.027），谱倾斜从 −18.9 变到 −28.2，shape RMSE 达到 7.19 dB（TSE 3.89 dB）。高频共振峰、辅音细节和精细谱包络正是声纹模型依赖的线索；这些被改写后，embedding 就会漂。谱形畸变与 embedding 漂移的相关系数为 −0.54（360 个“语句×条件”点），而 SI-SDR 与漂移只有 +0.13——坏在谱形，不在残余噪声。

4.7 Embedding 轨迹

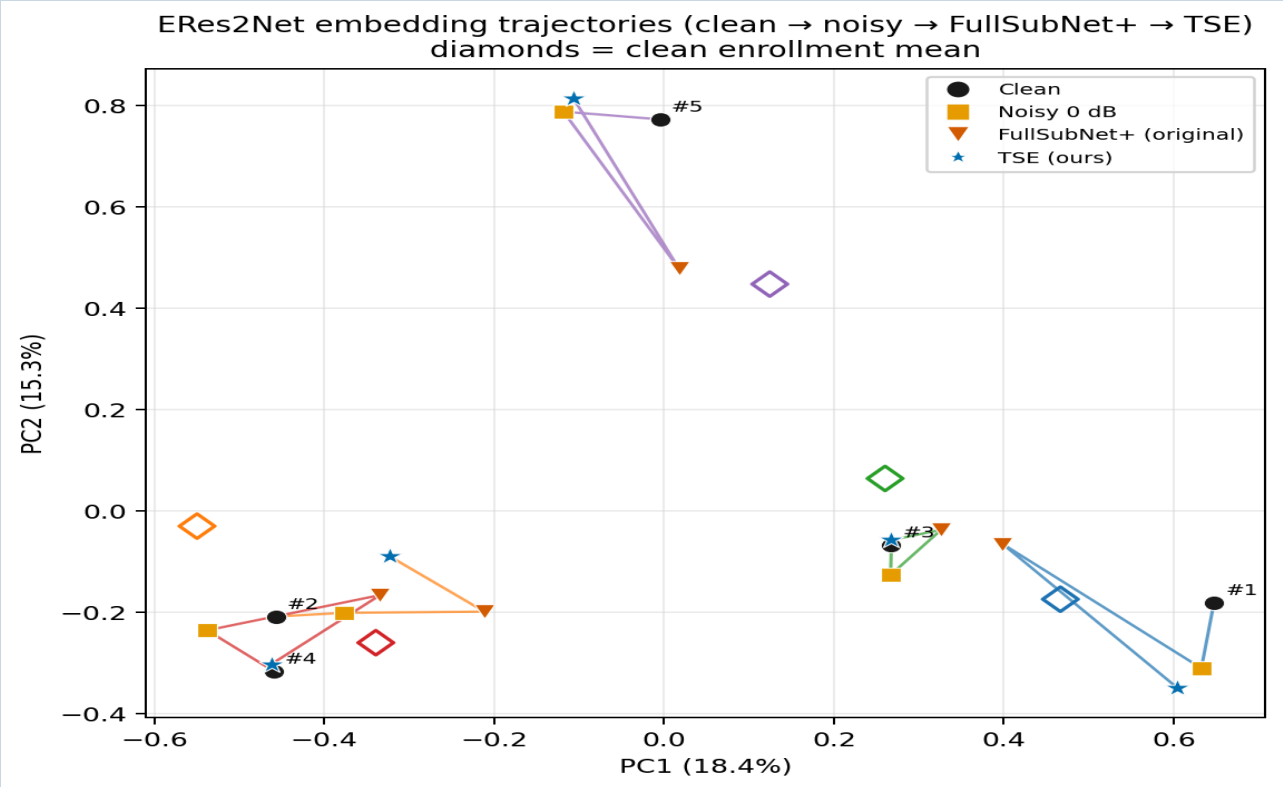


图 4-11　5 条样本的 ERes2Net embedding 轨迹（clean → noisy → 原方法 → TSE）；菱形为 clean 注册均值。原方法通常被推到远离 clean 的位置；TSE 更靠近 clean/注册中心。

PCA 图只有 5 条样本，是示意性的，但与 8,507 条统计一致。注意 TSE 的 cos 到 clean 只有 0.816，和 Noisy 的 0.820 接近；但 TSE 的 target 更高（0.471 vs 0.422）。它不是“更像 clean 的录音”，而是“更像注册的这个人”——这是注册条件化的本质。

4.8 结果小结

- **验证：**原方法 EER 10.113%、target 0.391、gap 0.332、d′ 2.544、drift 0.714；TSE 4.892%、0.471、0.418、3.416、0.816。
- **信号/感知：**原方法 SI-SDRi +8.59 dB、VAD-SNRi +15.67 dB、PESQ 1.889、STOI 0.750；TSE +7.62、+8.40、1.958、0.739。原方法三项更好，PESQ 略低。
- **全局 SNR（输入同电平）：**0 dB 原方法 +3.80 dB、TSE +3.32 dB；−5 dB +3.16 / +2.57 dB。
- **频谱：**原方法 high 占比 0.018（clean 0.027）、谱倾斜 −28.2、shape RMSE 7.19；TSE 0.036、−22.2、3.89。
- **一句话：**原方法是一个更好的“降噪器”，但 TSE 是一个更好的“声纹前端”。

5 失效机理：为什么原方法会坏

原报告已经给出了 TSE 的网络结构、FiLM 注入与四项损失；本节不重复模型介绍，只解释“为什么通用降噪会让声纹变差”，以及 TSE 为什么能避开这个问题。

5.1 原 FullSubNet+ 的失效链

环节	观察	解释
① 目标函数	FullSubNet+ 优化 cIRM/信号重建，训练分布是 DNS 类通用数据；没有注册条件。	它优化“增强信号像 clean”，不优化“增强后仍像同一个人”；也不知道要保留谁。
② 频谱行为	high 频带占比 0.166 → **0.018**；谱倾斜 -18.9 → **-28.2**；shape RMSE 7.19 dB；输出峰值归一化到 0.8。	高频目标语音细节被过度压制，低频/宽带能量被抬升；增益和伪影进一步改变谱包络。
③ embedding	同句 cos 到 clean：0.820 → **0.714**；target 0.422 → 0.391；gap 0.371 → 0.332；d' 2.752 → 2.544。	ERes2Net 依赖的精细谱结构被改写，embedding 离开说话人流形；注册相似度和类间可分性同时下降。
④ 系统结果	EER 8.391% → **10.113%**，比不处理还差 1.72pp。	波形/感知指标可以更好，但验证指标由 embedding 决定，所以“降噪更好”没有转化为“声纹更好”。

这条链的关键是 ②→③：如果只看波形，原方法确实更接近 clean（SI-SDR 8.07 dB、VAD-SNR 20.69 dB、STOI 0.750）；但 ERes2Net 不直接“看波形”，它看的是 FBank 的精细谱包络。谱形被改写后，embedding 漂移比“完全不处理”还大。这也是为什么“降噪指标”和“声纹指标”会背离。

> **一句话：** 原方法不是“降噪把语音压没了”，而是“降噪把说话人 embedding 推到了错误方向”。它优化的是信号重建，不是身份保持；高频细节的过度压制和低频/增益伪影是中间机制，embedding 漂移和 target 下降是直接原因，EER 变差是最终结果。

5.2 TSE 为什么能保住身份

- **注册条件化：**注册 embedding 经 FiLM 注入 FullSubNet+，增强时模型知道“保留谁”，可以把非目标语音/噪声压掉，而不是把所有语音能量都当目标。
- **说话人保持损失：**训练时约束增强前后 embedding 的余弦，使增强后的语音仍然落在注册者的 embedding 附近；这直接对齐了声纹目标。
- **难负原型抑制：**对最难的干扰说话人原型做间隔惩罚，增大 target 与 hard negative 的分离度；d' 从 2.752 提到 3.416。
- **不是复刻 clean：**TSE 的 cos 到 clean 只有 0.816（与 Noisy 0.820 接近），但 target 是 0.471（Noisy 0.422）。它把语音往“注册的这个人”方向拉，而不是简单复制 clean 录音。

TSE 的 FiLM 结构、四项损失、消融链与训练细节见原报告第 5 章；本报告只保留“它为什么能改善声纹”这条因果链。

5.3 边界与引用注意

- **Oracle 口径**：本报告 TSE 的 4.892% 是 oracle 口径（用测试句真实说话人的注册语音做条件），对应交付主表；claim 口径（冒认句用声称者的注册条件）存在条件信息泄漏，EER 会反弹，不能把 4.892% 直接外推到真实部署。完整分析见原报告附录 C（部署口径与局限性）。
- **条件**：主分析是 0 dB；-5 dB 只补充了 EER/全局 SNR/SI-SDR。PESQ/STOI 的绝对值受跨设备 clean 参考和 0 dB 条件影响，应看相对提升。
- **样本量**：信号/感知/频谱指标在 120 条随机测试句上统计；5 条展示样本用于可视化，不是统计结论的全部依据；逐句 target/漂移覆盖 8,507 条测试句。
- **对比**：原方法是通用 FullSubNet+，TSE 是在其基础上加入注册条件与身份损失训练得到的；这是“两条工程路线”的对比，不是“同预算、同目标”的消融。结论是“在本项目的数据和协议上，身份条件化更适合声纹前端”，不是“所有通用降噪都一定有害”。
- **指标**：SI-SDR/SNR/PESQ/STOI 是信号/感知指标，不是说话人身份指标；全局 SNR 与 VAD-SNR 是不同定义，不能互换或相加。

6 结果查看指南：wav、图、数据分别在哪里

本 PDF 是结论与图的静态版本；如果看完想听声音、看原始图或查更多数字，按下面索引去对应文件。所有路径以 `E:\china_mobile_review\声纹特征对比\` 为根目录。

6.1 一分钟上手

我想…	打开/查看	说明
边听边看结论	listen.html	交互式 HTML：5 条样本四路音频、时频图、target 分数、全部关键图。
看正式补充报告	本 PDF	你正在看的文件；指标公式、定量结果、查看指南。
看原报告	原技术报告《多条件中文声纹识别与噪声鲁棒性增强》	任务/数据/协议/TSE 结构/主 EER 大表；本补充不重复。
看文字版	分析报告.md	Markdown 版本，便于复制到论文/笔记。

6.2 我想听 wav

最快的方式是打开 listen.html；每条样本都有 Clean / Noisy / FullSubNet+ / TSE 四个播放器。也可以进入下表文件夹，四个文件就是四路音频。试听副本在 `wav_listen/`（统一到 −23 dBFS RMS，避免原 FullSubNet+ 峰值归一化导致“听起来更响”的错觉）；原始响度在 `wav/`。

#	样本	试听文件夹	四个文件名
1	06975_005	wav_listen/…06975_005…	clean.wav / noisy_0db.wav / fullsubnetplus.wav / tse.wav
2	06868_001	wav_listen/…06868_001…	同上 + enroll_1.wav
3	06979_001	wav_listen/…06979_001…	同上 + enroll_1.wav
4	06811_006	wav_listen/…06811_006…	同上 + enroll_1/2.wav
5	06182_009	wav_listen/…06182_009…	同上 + enroll_1/2.wav

6.3 我想看某张图

图	文件	看什么
四联总图	metrics_summary.png	EER、target、gap、d′ 一页看完。
target 分布	target_score_distributions.png	8,507 条逐句 target 分数；原方法整体左移。
embedding 漂移	cos_to_clean_distributions.png	同句 clean vs 各条件 embedding 的余弦；原方法 0.714。
5 条样本分数	target_scores_selected.png	5 条样本四路 target 分数。
SI-SDR/PESQ/STOI	intrusive_metrics.png	120 条随机样本的三项均值±标准差。
PESQ vs SNR	pesq_vs_snr.png	解释 0 dB 下 PESQ 为什么只有 ~1.3。
降噪后全局 SNR	global_snr_inputmatched.png	0/-5 dB 下 Noisy/原方法/TSE 的全局 SNR。
时频图（样本 1）	spectrogram_…06975_005….png	四路 log-mel 对比。
时频差（样本 1）	spectrogram_diff_…06975_005….png	Noisy/原方法/TSE 分别减 clean。
频带差	mel_band_diff.png	120 条样本的平均频带差；原方法低频抬升、高频压低。
embedding 轨迹	embedding_pca.png	PCA 轨迹；原方法红三角偏离，TSE 蓝星靠近。
其余 4 条时频图	figs/ 文件夹	`spectrogram_3D_SPK_06182… / 06811… / 06868… / 06979…`

6.4 我想看更多数字

文件	规模	内容
data/per_utt_scores.csv	8,507 行	逐句 clean/noisy/原方法/TSE 的 target 分数、漂移、注册 ID。
data/intrusive_metrics.csv	120×3 行	SI-SDR、VAD-SNR、PESQ、STOI 及相对 Noisy 的提升。
data/global_snr_inputmatched.csv	120×3×2 行	0/-5 dB 下与输入同电平的全局 SNR 与 ΔSNR。
data/audio_features.csv	120×3 行	频带占比、谱倾斜、RMS 增益、shape RMSE、SI-SDR。
data/selected_intrusive_metrics.csv	5×3 行	5 条展示样本的逐句信号/感知指标。
data/summary.json	—	8507 条全局指标、阈值、选样信息。
data/intrusive_metrics_summary.json	—	SI-SDR/SNR/PESQ/STOI 的均值/中位数/改善比例。
data/global_snr_inputmatched_summary.json	—	0/-5 dB 全局 SNR 的均值/中位数/标准差。
data/pesq_snr_sweep.csv	20×6 行	20/10/5/0/-5 dB 的 PESQ/STOI 扫描。
data/selected_embeddings.npz	5×4×512	5 条样本四路 embedding + 注册均值（numpy npz）。

6.5 复现脚本与服务器路径

脚本	作用
sv_analyze.py	1,378,206 trial 分数、EER、target/gap/d′ 、embedding 漂移、选样。
sv_figs.py	样本 wav、时频图、差异图、PCA、分数分布图。
sv_audio_features.py	120 条随机样本的频带/谱倾斜/shape RMSE/相关性。
sv_intrusive_metrics.py	120 条随机样本的 SI-SDR / VAD-SNR / PESQ / STOI。
global_snr_denoised.py	降噪后全局 SNR（raw / active-RMS / SI-SDR 三种口径）。
global_snr_inputmatched.py	降噪后全局 SNR（与输入同电平，主表口径）。
snr_definitions.py	0/-5 dB 数据的全局 SNR、SI-SDR、VAD-SNR 对照。
pesq_snr_sweep.py	PESQ/STOI 随输入 SNR 的扫描。

服务器端：`ligangrui@10.20.1.95:/home/ligangrui/china_mobile/AI/10.17/`；Python 环境 `/home/ligangrui/china_mobile/zhangqiyuan/bin/python`。原方法 checkpoint `AI/8.17/models/best_model.tar`；TSE checkpoint `AI/8.27/exp/tse_v3_ns05duraug_r5/checkpoint_best.tar`。所有指标都直接从原始增强 wav 与官方 embedding 计算，没有重训。

7　面试速答与口径建议

7.1 三句话版本

① **现象**：通用 FullSubNet+ 把 0 dB EER 从 8.39% 推到 10.11%，比不处理还差；注册条件化 TSE 把它降到 4.89%。
② **证据**：原方法的 SI-SDR/SNR/STOI 其实更好，但它把 ERes2Net embedding 到 clean 的余弦从 0.820 拉到 0.714，target 从 0.422 降到 0.391，高频能量占比从 0.166 压到 0.018。
③ **机理**：通用降噪优化“像 clean”，不优化“像这个人”；TSE 用注册 embedding 经 FiLM 注入 + 说话人保持损失 + 难负原型抑制，优化“增强后仍像注册者”，所以信号指标不占优，声纹指标全面更好。

7.2 常见追问

问题	建议回答（带数字/口径）
为什么通用降噪后 EER 反而变差？	它优化 cIRM/信号重建，不是说话人身份。0 dB 下 SI-SDRi +8.59 dB、STOI +0.096，确实更干净；但同句 embedding 到 clean 的余弦只有 0.714（Noisy 0.820），target 0.391（0.422），gap 0.332（0.371），d′ 2.544（2.752）。波形更接近 clean，embedding 却被推离了说话人流形。
怎么证明是声纹特征被破坏，而不是噪声没降干净？	① 它的 SI-SDR/VAD-SNR/STOI 都比 Noisy 和 TSE 高（或部分更高），不是“没降噪”；② 谱形畸变（shape RMSE 7.19 dB）与 embedding 漂移的相关系数是 −0.54（360 个语句×条件点），而 SI-SDR 与漂移只有 +0.13。坏的中间量是谱形/embedding，不是残余噪声。
TSE 为什么能改善？	注册 embedding 经 FiLM 注入，让增强知道保留谁；说话人保持损失约束增强前后 embedding 余弦；难负原型抑制增大 target 与 hard negative 的间隔。结果 target 0.471、gap 0.418、d′ 3.416、EER 4.89%，都优于原方法和 Noisy。它不是复刻 clean：cos 到 clean 0.816 与 Noisy 0.820 接近，但 cos 到注册语音更高。
SNR 提升了多少？	先说口径。① 全局 SNR（输出缩放到与输入同 RMS）：0 dB 下原方法 0.16→3.96（+3.80 dB），TSE 0.16→3.48（+3.32 dB）；−5 dB 下 −4.53→−1.37（+3.16）/ −1.96（+2.57）。② SI-SDRi（尺度不变）：+8.59 / +7.62 dB（0 dB），−5 dB +11.47 / +9.59 dB。③ VAD-SNRi（分段噪声底）：+15.67 / +8.40 dB（0 dB）。三个不是同一个量，不能相加或互换。
PESQ 为什么只有 1.9？	测试是 0 dB，PESQ 是全参考、非线性指标，4.644 只对 clean-vs-clean 成立。用实际噪声扫 SNR：20 dB→3.18、10 dB→2.15、5 dB→1.69、0 dB→1.32、−5 dB→1.19；实际 noisy PESQ 1.333，与 0 dB 点吻合。1.9 已经是 0 dB 下的合理提升，不能和 clean 的 4.6 做百分比。
claim 口径怎么样？	本报告和交付主表是 oracle 口径（真实说话人注册），4.89% 是验收上限；claim 口径（冒认句用声称者注册条件）存在条件信息泄漏，EER 会反弹，不能直接外推到部署。完整分析见原报告附录 C（部署口径与局限性）。

7.3 容易踩的坑

> **建议的报法：**主结果（EER/minDCF/claim）引用原报告；本补充报告报 SI-SDRi + PESQ/STOI + 全局 SNR Δ，并明确每个 SNR 的定义。不要把 VAD-SNRi 当输出 SNR，也不要在 0 dB 下拿 PESQ 绝对值和 clean 的 4.644 比。

- 只说“降噪把声纹抹掉了”：太笼统。要加证据：embedding 漂移 0.714、target 0.391、高频占比 0.018、shape RMSE 7.19。
- 把 VAD-SNR 的提升直接说成“输出 SNR”：+15.67 dB 是 VAD-SNRi，不是“0 dB → 15.67 dB”；全局 SNR 提升是 +3.80 dB（0 dB 数据，输入同电平口径）。
- 拿 PESQ 1.9 和 clean 4.6 做百分比：PESQ 非线性，0 dB 下 1.3 是正常起点；要说“相对 Noisy 提升 +0.584 / +0.653”。
- 把 oracle 的 4.89% 说成部署性能：claim 口径会反弹；主动说明边界。
- 说“通用降噪一定有害”：更准确的说法是“在本项目数据/协议上，无条件通用降噪与声纹目标错位；身份条件化更合适”。

附录 A　产物、参数与复现

A.1 本补充报告使用的原始产物

用途	路径
原方法 checkpoint	`AI/8.17/models/best_model.tar`
原方法增强 wav（0 dB）	`.../sv-ecapa/data/data_for_test/denoised/noise_0db/enhanced_0194/`
原方法 embedding（0 dB）	`.../sv-ecapa/exp/clean_bench/denoised_noise_0db/eres2net/embeddings_3s/`
TSE checkpoint	`AI/8.27/exp/tse_v3_ns05duraug_r5/checkpoint_best.tar`
TSE 增强 wav（0 dB / −5 dB）	`AI/8.27/exp/tse_v3_ns05duraug_r5/enhanced_official/noise_0db|noise_m5db/`
TSE embedding / EER（0 dB / −5 dB）	`AI/8.28/final_eval_r5/r5_eres_noise_0db_3s|r5_eres_noise_m5db_3s/`

A.2 本补充新增的参数与口径

项目	设置
随机子集	120 条测试语音，随机种子 2026
展示样本	5 条：06975_005、06868_001、06979_001、06811_006、06182_009
VAD 分段	帧长 512、帧移 256；clean 能量最高 60% 为语音帧、最低 20% 为噪声帧
SI-SDR / 全局 SNR	先对齐（cross-correlation，最大 800 样点）；SI-SDR 用最优 α；全局 SNR 用输入整体 RMS 匹配
PESQ / STOI	官方 `pesq` 0.0.4（wb，16 kHz）；`pystoi` 0.4.1（extended=False）

原报告的 3D-Speaker 数据、clean 注册、1,378,206 条 trial、ERes2Net-large 后端与 EER/minDCF 定义不在本附录重复，见原报告第 2–3 章。

A.3 一致性检查

- 复算 EER 与官方 `result.metrics` 对账：clean 5.2928 / noisy 8.3912 / 原方法 10.1132 / TSE 4.8921（差异仅来自四舍五入）。
- 用官方 ERes2Net 重新抽取 5 条样本的 embedding，与落盘 embedding 余弦 0.96–0.997，确认听的 wav 与算的 embedding 是同一批。
- clean-vs-clean PESQ 4.644、STOI 1.000；实际 noisy 的 PESQ 1.333，与 0 dB 扫描点 1.323 吻合。
- 原方法 raw 全局 SNR −18.1 dB 来自峰值归一化增益；匹配到输入 RMS 后为 3.96 dB。

复现：服务器 `ligangrui@10.20.1.95:/home/ligangrui/china_mobile/AI/10.17/`；Python `/home/ligangrui/china_mobile/zhangqiyuan/bin/python`；脚本见 6.5；本 PDF 由 `build_supplement_report.py` 生成。

附录 B　新增参考

1. Le Roux J., et al. SDR — Half-Baked or Well Done? ICASSP, 2019.（SI-SDR）
2. ITU-T Recommendation P.862. Perceptual Evaluation of Speech Quality (PESQ), 2001；P.862.2 Wideband extension, 2005.
3. Taal C. H., et al. An Algorithm for Intelligibility Prediction of Time-Frequency Weighted Noisy Speech. IEEE TASLP, 2011.（STOI）
4. Garcia-Romero D., et al. How Good is Enhancement for Speaker Verification? Odyssey, 2020.
5. Sadiku S., et al. Investigation of Speech Enhancement and Recognition-Based Front-Ends for Robust Speaker Verification. Interspeech, 2022.

原报告的 3D-Speaker、ERes2Net、FullSubNet+、FiLM 与 TSE 相关工作引用见原报告参考文献；本附录只列本补充新增的指标/机理参考。